

实验 01

舞蹈模仿

舞蹈模仿：将定时编舞作为反馈控制

环境设计 · PPO · 如实验证

构建 → 训练 → 验证 → 讲解



你将构建什么？现有证据说明了什么？

- 01 用例：讲解 PPO 如何将按时间索引的关节片段转化为平衡的 50 Hz 反馈控制器，然后通过确定性 ONNX 跟踪和空白对照证明动作效果。
- 02 学习目标：描述场景，解释观测到动作的映射和奖励，追踪一次 PPO 更新，运行有限预算实验，并用证据支撑评估结论。
- 03 本结论仅涵盖一个八秒片段，不涵盖完整的 60.923 秒源片段或任意编舞。
- 04 适用范围：本地 MuJoCo 仿真。请勿将课堂产物直接部署到实体机器人；硬件迁移需要独立且经过验证的流程。

材料与准备条件 · 1/2

- 01 配备已安装的 RLX 环境、MLX、MuJoCo、ONNX、ONNX Runtime、Pillow、ImageIO 和 FFmpeg 的 Apple Silicon Mac。
- 02 源编舞：dance-clip/bachata_microduck_v2.clip.json；所选证据使用其最初未经缩放的八秒。
- 03 准备好的 400 姿态参考：rlx/artifacts/dance-e2e-20260907/reference.clip.json。
- 04 训练和审计工具：ppo_microduck_studio.py、dance_e2e.py、audit_dance.py，以及 Studio HTTP 驱动程序。

材料与准备条件 · 2/2

05

已保存检查点、归一化 sidecar、确定性 ONNX 策略网络（Actor）、评估 JSON、MP4、缩略图表和 JSONL 遥测数据。

环境与策略接口约定 · 1/2

- 01 使用 XML 位置执行器的标称本地 MuJoCo；物理 dt 0.005 s，抽取率 4，控制 dt 0.02 s，即 50 Hz。
- 02 观测契约为 float32 batch x 61：陀螺仪 0:3，重力 3:6，关节位置 6:20，滞后速度 20:34，上一个动作 34:48，命令 48:61。
- 03 舞蹈通过将身体命令索引 59 和 60 替换为 $\sin(\text{phase})$ 和 $\cos(\text{phase})$ 来保持共享契约；扭转命令为零。
- 04 动作契约为 float32 batch x 14，采用部署关节顺序；存储原始策略网络（Actor）均值，应用的偏移量裁剪至 $[-4, 4]$ rad，然后加上 DEFAULT_POSE。

环境与策略接口约定 · 2/2

05

所选运行禁用了域随机化、观测噪声、动作延迟和随机偏航；常规重置扰动仍然保留。

06

片段加载器使用 14 个关节目标和 rootPitch；编写的根部偏航、横滚、位置和接触标注不作为模仿目标。

案例构建流程：以证据形成验证闭环



失败也是数据：每次只改变一个因素，重新训练，并使用相同的验收标准。

逐步构建本案例 · 1/2

- 01 对 60.923 s 源片段进行哈希，并准备一个循环播放、未经缩放的八秒摘录，采样为 400 个控制频率姿态。
- 02 创建 Dance 配方，逐关节高斯姿态精度 σ 0.2，16 个环境，128 步 rollout，以及全新的策略网络（Actor）和价值网络（Critic）权重。
- 03 训练随机性 PPO，同时分别记录归一化采集奖励、原始已完成回合回报和实际小批次优化器指标。
- 04 在 rollout 边界保存检查点，其中包括观测与奖励归一化统计数据以及准确的配方元数据。

逐步构建本案例 · 2/2

05

将确定性策略网络（Actor）均值导出到 ONNX，并嵌入观测归一化；不导出价值网络（Critic）和动作采样。

06

运行严格的完整回合评估，然后渲染导出的策略，并独立比较已训练、零动作、未训练和冻结相位对照。

PPO：改进策略，同时避免盲目迈出过大一步

$$\text{似然比 ratio} = \pi_{\text{new}}(a \mid o) / \pi_{\text{old}}(a \mid o)$$

最大化 $\text{mean}[\min(\text{ratio} \times A, \text{clip}(\text{ratio}, 1 - \epsilon, 1 + \epsilon) \times A)]$

策略网络（Actor）：选择关节动作。价值网络（Critic）：估计未来折扣奖励。

A 表示优势； ϵ 表示裁剪范围。每个采样批次的旧策略对数概率在更新时保持不变。

沿着一次轨迹采样，理解学习器的处理过程

- 01 使用当前随机策略采集观测、采样动作、旧策略对数概率、价值估计、奖励以及回合边界标记。
- 02 计算时序差分残差和广义优势估计（GAE）。真正终止时，后续价值为零；超时截断时，可以使用保存的最终观测进行价值自举。
- 03 在重置边界切断优势递推。不得使用下一回合的初始观测，对上一回合的超时状态进行价值自举。
- 04 重复使用同一批数据进行 PPO 小批次更新，再采集新的同策略数据。评估时导出确定性策略网络及其观测变换。

纸笔练习：计算样本数与裁剪目标

- 01 教学算例，并非本次实验：16 个环境 $\times$ 128 步 = 每次采样得到 2,048 条新转移。四轮优化重复使用这些转移，并不会产生 8,192 条新样本。
- 02 当 $\epsilon = 0.2$ 、 $\text{ratio} = 1.4$ 、 $A = +2$ 时： $\min(2.8, 2.4) = 2.4$ 。在求平均和加入其他损失项之前，被最小化的策略项为 -2.4 。
- 03 保持相同的 ratio ，令 $A = -2$ ： $\min(-2.8, -2.4) = -2.8$ 。请解释：优势符号改变后，裁剪为何呈现不对称效果？
- 04 在仓库根目录运行：`python3 docs/microduck-training-student-book/learning_lab.py --gae`。这是确定性的算术练习，不会训练新策略。

奖励设计：智能体因何获得奖励？ · 1/2

- 01 pose_match 40: 各关节 $\exp(-((q - q_{\text{ref}})/0.2)^2)$ 的均值，替代继承而来的更宽泛姿态核。
- 02 rotation_match 4: 奖励与片段参考根部俯仰一致的表现。
- 03 on_feet 5: 奖励在跟随编舞时有支撑、保持直立的物理执行。
- 04 no_slip 0.5 和 no_spin 0.3: 针对脚部打滑和过度旋转的非正惩罚。

奖励设计：智能体因何获得奖励？ · 2/2

05

gentle_head 1、soft_landings 0.75、no_limit_parking 1 和 save_energy 0.0005 是启用的惩罚项。

06

travel 0 禁用向前移动奖励；stick_it 5 存在但未启用，因为所选参考是循环的。

已记录的训练配置 · 1/2

- 01 实际所选运行：seed 7，全新 PPO，4,001,792 次转移，16 个 fork 环境，每个环境 128 步，每次 rollout 2,048 次转移。
- 02 PPO 使用 4 个小批次 x 4 个 epoch：每个小批次 512 行，每次 rollout 16 个优化器步骤，共 1,954 次 rollout 和 31,264 个优化器步骤。
- 03 学习率 0.0001；gamma 0.99；广义优势估计（GAE）lambda 0.95；clip 0.2；价值系数 1；熵系数 0；最大梯度范数 0.5。
- 04 初始动作标准差为 0.1；策略网络（Actor）和价值网络（Critic）是彼此独立的 61–512–256–128 网络，使用 ELU 激活函数。

已记录的训练配置 · 2/2

05

启用观测归一化和折扣回报奖励归一化；观测统计数据被冻结到导出的 ONNX 图中。

06

更新日志字段：phase、steps、seconds、optimizer_steps、mean_loss、policy_loss、value_loss、entropy、approximate_kl、clip_fraction、explained_variance、env_steps。

实操命令：检查、冒烟测试与训练 · 1/3

01

工作目录：.
`./scripts/train-dance.sh --dry-run`
在不训练的情况下检查当前随附的 Dance 流水线。

02

工作目录：.
`./scripts/train-dance.sh`
运行当前独立的 Full Dance 流水线，并生成带全新时间戳的输出。

实操命令：检查、冒烟测试与训练 · 2/3

03

工作目录： `.`
`rlx/.venv-microduck/bin/python rlx/scripts/dance_e2e.py --source dance-clip/bachata_microduck_v2.clip.json --output rlx/artifacts/dance-reproduction-YYYYMMDD-HHMMSS --seconds 8 --train-steps 4001792 --run-name dance-e2e-reproduction-YYYYMMDD-HHMMSS`
准备准确的历史八秒 Bachata 参考和配方；一致地替换时间戳标记。

04

工作目录： `.`
`rlx/.venv-microduck/bin/python rlx/scripts/audit_dance.py --run rlx/runs/studio/dance/dance-e2e-reproduction-YYYYMMDD-HHMMSS --recipe rlx/artifacts/dance-reproduction-YYYYMMDD-HHMMSS/recipe.json --output rlx/artifacts/dance-reproduction-YYYYMMDD-HHMMSS/audit --seeds 101 102 103 104 105 --history-stride 2 --render`
在不进一步进行 PPO 训练的情况下，使用留出 seed 审计已完成的准确配方复现。

实操命令：检查、冒烟测试与训练 · 3/3

05

工作目录：.




```
rlx/.venv-microduck/bin/python -m pytest rlx/tests/test_dance_evaluation.py
```

```
rlx/tests/test_dance_pipeline.py rlx/tests/test_microduck_dance.py
```

运行聚焦于 Dance 契约和评估的测试。

奖励：日志信号与真正的任务目标一致吗？





奖励记录：定义不同的信号，不能混为一谈



训练奖励是优化信号，不是验收标准。完整记录字段见 `raw/<case>/`。

损失：观察策略、价值估计与策略漂移



PPO 优化记录：原始数值，未经平滑



损失更低，不等于机器人技能更好。损失的符号和数值尺度取决于具体实现。

诊断：优化器的行为正常吗？

更新诊断：明确标注未记录的字段



熵、裁剪比例、解释方差和耗时都是诊断指标，不能单独构成通过或失败的证明。

指标矩阵：本次日志的数值审计 · 1/3

- 01 approximate_kl: 首次 7.759 → 最终 0.08225; 最小值 0.03034, 最大值 7.759; 记录了 1954 个样本。
- 02 clip_fraction: 首次 0.9050 → 最终 0.4437; 最小值 0.3440, 最大值 0.9050; 记录了 1954 个样本。
- 03 entropy: 首次 -12.38 → 最终 -14.10; 最小值 -14.10, 最大值 -12.27; 记录了 1954 个样本。
- 04 explained_variance: 首次 -0.006817 → 最终 0.9283; 最小值 -0.1084, 最大值 0.9960; 记录了 1954 个样本。

指标矩阵：本次日志的数值审计 · 2/3

- 05 mean_loss: 首次 2.261 → 最终 0.01790; 最小值 -0.03312, 最大值 2.261; 记录了 1954 个样本。
- 06 mean_raw_return: 首次 1234 → 最终 5343; 最小值 940.8, 最大值 1.788e+4; 记录了 11820 个样本。
- 07 mean_reward: 首次 0.2507 → 最终 0.04188; 最小值 0.03332, 最大值 0.2507; 记录了 1954 个样本。
- 08 policy_loss: 首次 0.08514 → 最终 -0.01620; 最小值 -0.03472, 最大值 0.1133; 记录了 1954 个样本。

指标矩阵：本次日志的数值审计 · 3/3

09

value_loss: 首次 2.176 → 最终 0.03411; 最小值 0.00004939, 最大值 2.176;
记录了 1954 个样本。

验证：查看结果前先定义成功标准 · 1/2

- 01 要求每个回合完成 400 个实测步骤且不终止，相位覆盖连续，轨迹均为有限值，并且至少 95% 的样本保持直立。
- 02 要求所有关节的姿态 RMSE ≤ 0.15 rad，相对于恒定参考均值基线的动态增益 ≥ 0.20 ，并且腿部动态增益为正。
- 03 要求至少两个腿部关节运动；所选参考有 12 个运动关节和 8 个运动腿部关节，阈值为 0.03 rad。
- 04 将确定性的已训练 ONNX 与零动作、未训练网络以及相位输入被冻结的已训练网络进行比较。

验证：查看结果前先定义成功标准 · 2/2

05

验证动态 batch x 61 输入和动态 batch x 14 输出、ONNX checker 成功、源哈希，以及原生/ONNX 动作一致性 $\leq 1e-4$ 。

06

检查完整 MP4 和带说明文字的缩略图表；仅凭奖励或有限值执行无法证明编舞效果。

结果：实际测量到了什么？ · 1/3

- 01 实际最终证据：dance-e2e-20260907-low-noise 为 PASS；Studio 评估通过了 16/16 个八秒回合，终止次数为零。
- 02 独立 seed 101-105 通过 5/5；平均姿态 RMSE 0.08438 rad，平均动态增益 38.39%，平均腿部增益 52.52%，直立覆盖率 100%。
- 03 三个 seed 通过了单独的 800 步、16 秒扩展测试，其中将学到的八秒摘录重复两次。
- 04 零动作通过 0/5，并在 43-49 步后跌倒；未训练网络在 37 步后跌倒；冻结相位在动态跟踪上通过 0/5。

结果：实际测量到了什么？ · 2/3

- 05 ONNX/原生最大动作误差为 $3.5762786865234375e-7$ ；学习张量相对初始化的 L2 变化为 12.247028438523373。
- 06 训练记录了 1,954 次有限值更新和 31,264 个优化器步骤；Final-100 policy_loss 为 -0.01673409083727165。
- 07 Final-100 value_loss 为 0.0030093801085240555, mean_loss 为 -0.013724710738842986。
- 08 Final-100 approximate_kl 为 0.053165218892099804, clip_fraction 为 0.430621337890625, explained_variance 为 0.8950924869797166。

结果：实际测量到了什么？ · 3/3

09

保存的渲染收据将 ep0.mp4 与 ONNX SHA-256
32c27fe239285f1be624b01f77eaa7a411262852c89d51404ae8398ac94bdbd9
绑定。

观看已保存的真实仿真轨迹



播放前

预测一个成功信号和一个失败信号。

播放后

这个片段能支持哪些结论？哪些问题仍未检验？

已保存的 8.0 s MP4 • 在 PowerPoint 幻灯片放映中单击 • 备用：videos/dance-rollout.mp4

局限与失败分析 · 1/2

- 01 本结论仅涵盖一个八秒片段，不涵盖完整的 60.923 秒源片段或任意编舞。
- 02 仅记录了一个成功的训练 seed；评估 seed 并不能衡量多个独立训练策略之间的可靠性。
- 03 与早期失败相比，该配方同时改变了探索尺度和样本预算，因此没有单独分离二者各自的因果效应。
- 04 根部平移、根部偏航、根部横滚和编写的接触均被忽略；仍存在可见滞后、髋部横滚偏移和头部偏航过冲。

局限与失败分析 · 2/2

05

该运行使用标称 XML 执行器，没有域随机化、BAM 审计、扰动、地形、延迟或硬件验证。

06

16 秒结果是同一循环的两次重复，并不能证明学会了未见过的源编舞。

学生实验：只改一个变量，保留验收标准 · 1/2

- 01 建议练习，并非已保存证据：重建所有观测切片，并识别相位索引 59 和 60。
- 02 建议练习，并非已保存证据：从 trained-seed101.npz 重新计算动态增益，不进行平滑、拟合滞后或时间平移。
- 03 建议练习，并非已保存证据：针对 4,000,000 次转移请求，计算 rollout 数、优化器计数和样本复用次数。
- 04 建议练习，并非已保存证据：检查 ONNX 名称、float32 形状，以及嵌入的均值、方差、epsilon 和 clip 常量。

学生实验：只改一个变量，保留验收标准 · 2/2

05

建议练习，并非已保存证据：设计一项包含五个训练 seed 的研究，使用固定配方和预先声明的留出门槛。

提交一个完整实验，而不只是一段视频

- 01 训练前：写下一个假设、要修改的参数、固定的基线、随机种子列表、验收标准，以及时间与转移数预算。
- 02 训练中：保存准确命令、环境版本、初始化方式、检查点，以及原始奖励、损失和 KL 指标。不得覆盖已有的参考运行。
- 03 训练后：使用相同随机种子评估冻结的导出策略；提交全部失败案例、汇总指标、完整轨迹视频和可追溯来源的结果表。
- 04 评分标准 / 10：可复现性 2；环境与奖励解释 2；PPO 与指标解读 2；如实验验证 2；一个有证据依据的后续实验 2。

来源索引与延伸学习 · 1/2

01

AGENTS.md

02

microduck_local/AGENTS.md

03

microduck_local/src/microduck_local/contract.py

04

microduck_local/src/microduck_local/walk_env.py

来源索引与延伸学习 · 2/2

05

`docs/microduck-training-student-book/chapters/02a-ppo-code-lab.md`

06

`docs/microduck-training-student-book/chapters/02b-gae-workshop.md`

07

`scripts/scenarios/README.md`

08

`README.md`