

## 实验 05

# 辅助后空翻

后空翻：辅助起跳→PPO 落地→预训练  
站立策略接管

环境设计 · PPO · 如实验证

构建 → 训练 → 验证 → 讲解



# 你将构建什么？现有证据说明了什么？

- 01 用例：通过三阶段仿真后空翻讲解控制器职责归属、迁移学习、PPO 诊断和证据边界。辅助器负责起跳能量和旋转，训练后的 PPO actor策略网络仅负责落地窗口，预训练站立策略负责最后的稳定站立。
- 02 学习目标：描述场景，解释观测到动作的映射和奖励，追踪一次 PPO 更新，运行有限预算实验，并用证据支撑评估结论。
- 03 这不是无辅助的学习后空翻。仿真器中的辅助器提供了大量起跳能量和旋转。
- 04 适用范围：本地 MuJoCo 仿真。请勿将课堂产物直接部署到实体机器人；硬件迁移需要独立且经过验证的流程。

# 材料与准备条件 · 1/2

- 01 采用 XML 位置伺服器、以 50 Hz 控制的 Microduck MuJoCo 模型
- 02 microduck/policies/alpha\_stand.onnx 既是 actor策略网络和观测归一化器的精确来源，也是落地后的站立控制器
- 03 rlx/rlx/environments/backflip.py 用于辅助起跳、仅落地奖励、阶段指标和接管逻辑
- 04 rlx/rlx/environments/backflip\_evaluation.py 用于独立的物理验收门槛

## 材料与准备条件 · 2/2

- 05 `rlx/rlx/models/backflip_bootstrap.py` 用于精确教师迁移、一致性检查、奖励校准和 critic 价值网络拟合
- 06 `rlx/examples/ppo_microduck_studio.py` 和 `scripts/train-backflip.sh` 用于训练、评估、渲染和导出
- 07 `rlx/runs/studio/backflip/backflip-e2e-20260908-v5/` 是保留的训练运行
- 08 `rlx/artifacts/backflip-e2e-20260908-v5/` 包含独立审计、图表、逐种子数组和来源信息

# 环境与策略接口约定 · 1/3

- 01 仅限仿真。协议 spotter-launch-landing-stand-v2 在起跳期间使用显式 MuJoCo 广义外力；它不会瞬移机器人。
- 02 控制契约：float32 观测形状为 61，动作形状为 14，频率为 50 Hz。动作是按固定伺服器顺序排列的 14 个关节目标偏移量。
- 03 观测索引 0:3 为躯干角速度；3:6 为投影重力；6:20 为关节位置偏移量；20:34 为滞后一个控制步的关节速度；34:48 为上一个原始动作；48:51 为 twist 命令；51:55 为头部命令；55:61 为身体命令。
- 04 落地 actor策略网络不会收到额外的阶段、相位、世界位置、偏航角、起跳力或接触通道。组合控制器代码知道当前阶段，但 PPO actor策略网络仍只接收标准的 61 个值。

## 环境与策略接口约定 · 2/3

- 05 起跳持续时间为 1.2 s。俯仰目标终止于 5.3 rad，目标速率为 5 rad/s；目标高度升至 0.32 m，并在释放前朝 0.22 m 降低。
- 06 起跳增益和限幅为：俯仰  $k_p$  1.5、俯仰  $k_d$  0.24、俯仰扭矩上限 1.3 Nm、垂直  $k_p$  90、垂直  $k_d$  8.5、垂直力上限 15 N、横向阻尼 3，以及滚转/偏航阻尼 0.1。
- 07 释放时必须至少达到 5.3 rad，且向后角速度在 3.5 和 6.5 rad/s 之间。释放时清除所有外力和外部扭矩。
- 08 接管要求计入的旋转至少为 5.8 rad，并有连续 10 个稳定的 PPO 样本：双脚均受支撑、无非足部支撑、直立投影至少为 0.9、躯干高度至少为 0.105 m、陀螺仪范数低于  $\sqrt{2}$  rad/s，且没有辅助器帮助。

## 环境与策略接口约定 · 3/3

09

接管后，alpha\_stand.onnx 必须维持最后连续 100 个稳定样本，相当于 2 s（频率为 50 Hz）。

## 案例构建流程：以证据形成验证闭环



失败也是数据：每次只改变一个因素，重新训练，并使用相同的验收标准。

## 逐步构建本案例 · 1/3

- 01 从不变的 61 观测/14 动作契约开始，并标明落地 actor策略网络实际能够观测哪些信号。
- 02 加载 alpha\_stand.onnx，并在迁移前验证其 512-256-128 ELU actor策略网络结构、61 个输入、14 个输出和观测归一化器。
- 03 收集 16 个教师落地 episode回合，每个 episode回合 600 步，从辅助释放状态生成 9,600 个校准样本。
- 04 精确复制教师 actor策略网络和归一化器，要求动作一致性误差低于  $1e-4$ ，并冻结观测归一化。

## 逐步构建本案例 · 2/3

- 05 仅拟合新建的 critic 价值网络，训练 10 轮，使用 Adam，学习率为  $3e-4$ ；在此校准期间保持迁移的 actor 策略网络不变。
- 06 每个训练 episode 回合都通过辅助起跳重置，然后将释放时的观测交给 PPO。辅助准备步骤不计入 PPO 转移次数，并获得零 PPO 奖励。
- 07 仅训练落地 actor 策略网络。PPO 数据收集期间不要运行站立策略覆盖。
- 08 使用确定性动作评估完整的三阶段控制器，并独立重建接管前的连续稳定记录。

## 逐步构建本案例 · 3/3

09 移除站立策略接管后运行仅落地审计，使 PPO actor策略网络必须自行保持最后 100 个样本。

10 在配对种子上将最终 actor策略网络与精确初始化和零动作对照进行比较；不要根据展示成功推断发生了学习。

11 渲染带阶段标签的 MP4 和接触表，然后在使用视频片段前验证策略、站立策略、评估和媒体哈希。

## PPO：改进策略，同时避免盲目迈出过大一步

$$\text{似然比 ratio} = \pi_{\text{new}}(a \mid o) / \pi_{\text{old}}(a \mid o)$$

最大化  $\text{mean}[\min(\text{ratio} \times A, \text{clip}(\text{ratio}, 1 - \epsilon, 1 + \epsilon) \times A)]$

策略网络（Actor）：选择关节动作。价值网络（Critic）：估计未来折扣奖励。

A 表示优势； $\epsilon$  表示裁剪范围。每个采样批次的旧策略对数概率在更新时保持不变。

# 沿着一次轨迹采样，理解学习器的处理过程

- 01 使用当前随机策略采集观测、采样动作、旧策略对数概率、价值估计、奖励以及回合边界标记。
- 02 计算时序差分残差和广义优势估计（GAE）。真正终止时，后续价值为零；超时截断时，可以使用保存的最终观测进行价值自举。
- 03 在重置边界切断优势递推。不得使用下一回合的初始观测，对上一回合的超时状态进行价值自举。
- 04 重复使用同一批数据进行 PPO 小批次更新，再采集新的同策略数据。评估时导出确定性策略网络及其观测变换。

## 纸笔练习：计算样本数与裁剪目标

- 01 教学算例，并非本次实验：16 个环境  $\times$  128 步 = 每次采样得到 2,048 条新转移。四轮优化重复使用这些转移，并不会产生 8,192 条新样本。
- 02 当  $\epsilon = 0.2$ 、 $\text{ratio} = 1.4$ 、 $A = +2$  时： $\min(2.8, 2.4) = 2.4$ 。在求平均和加入其他损失项之前，被最小化的策略项为  $-2.4$ 。
- 03 保持相同的  $\text{ratio}$ ，令  $A = -2$ ： $\min(-2.8, -2.4) = -2.8$ 。请解释：优势符号改变后，裁剪为何呈现不对称效果？
- 04 在仓库根目录运行：`python3 docs/microduck-training-student-book/learning_lab.py --gae`。这是确定性的算术练习，不会训练新策略。

# 奖励设计：智能体因何获得奖励？ · 1/2

- 01 名称：landing\_upright | 权重：3 | 符号：奖励 | 定义： $\text{clip}((1 - \text{projected\_gravity\_z}) / 2, 0, 1)$  | 范围：仅 PPO 落地阶段
- 02 名称：landing\_pose | 权重：2 | 符号：奖励 | 定义：landing\_upright 乘以等权 0.60-rad 和 0.15-rad 高斯姿态核的均值 | 范围：仅 PPO 落地阶段
- 03 名称：landing\_settle | 权重：1 | 符号：奖励 | 定义：landing\_upright 乘以姿态分数，再乘以  $\exp(-\text{sum}(\text{gyro squared}) / 2)$  | 范围：仅 PPO 落地阶段
- 04 名称：landing\_joint\_speed\_penalty | 权重：0.05 | 符号：惩罚 | 定义： $-\text{mean}(\text{min}(\text{joint\_velocity squared} / 100, 1))$  | 范围：仅 PPO 落地阶段

## 奖励设计：智能体因何获得奖励？ · 2/2

05

名称：landing\_action\_rate\_penalty | 权重：0.02 | 符号：惩罚 | 定义： $-\text{mean}(\min((\text{action} - \text{previous\_action})^2, 1))$  | 范围：仅 PPO 落地阶段

06

名称：landing\_action\_size\_penalty | 权重：0.01 | 符号：惩罚 | 定义： $-\text{mean}(\min(\text{action}^2 / 16, 1))$  | 范围：仅 PPO 落地阶段

07

名称：total\_reward | 权重：null | 符号：有界总和 | 定义： $3 * \text{landing\_upright} + 2 * \text{landing\_pose} + \text{landing\_settle} + 0.05 * \text{landing\_joint\_speed\_penalty} + 0.02 * \text{landing\_action\_rate\_penalty} + 0.01 * \text{landing\_action\_size\_penalty}$ ；范围从 -0.08 到 6 | 范围：辅助起跳和预训练站立策略接管期间，每个分量均为零

## 已记录的训练配置 · 1/2

- 01 配置：transition\_budget | 值：401408 | 详情：196 个完整批次，每批 16 个环境 x 128 步；不包括辅助重置准备
- 02 配置：ppo\_batch | 值：16 个环境，每个环境 128 步，4 个小批次，2 轮更新
- 03 配置：optimizer | 值：Adam 学习率  $3e-6$ ，最大梯度范数 0.5，新建 PPO 优化器
- 04 配置：discount\_and\_objective | 值：gamma 0.99，GAE广义优势估计 lambda 0.95，裁剪系数 0.2，启用裁剪价值损失，价值系数 1.0，启用优势归一化

## 已记录的训练配置 · 2/2

05 配置：探索 | 取值：初始动作标准差 0.03，熵系数 0

06 配置：normalization | 值：冻结迁移的观测归一化；启用奖励归一化，并在教师校准后冻结；校准后的折扣回报标准差为 147.2994092878347

07 配置：episode\_and\_randomization | 值：12 s episode回合，种子 7，XML 执行器，虚拟向量后端，关闭域随机化，关闭观测噪声，关闭动作延迟，关闭随机偏航角

08 配置：telemetry\_fields | 值：phase；env\_steps；steps；seconds；optimizer\_steps；mean\_loss；policy\_loss；value\_loss；entropy；approximate\_kl；clip\_fraction；explained\_variance；mean\_reward；mean\_raw\_return

# 动手命令：检查、冒烟测试、训练 · 1/2

## 01

工作目录：duck-viewer

```
npm run dev
```

在 API 复现驱动程序之前启动 Studio 服务。

## 02

工作目录：duck-viewer

```
node scripts/rlx-dance-api-e2e.mjs --execute --experiment backflip --run backflip-  
reproduction-001 --profile full --recipe-json ../docs/backflip-showcase/recipe.json --  
report ../.restart-lab/backflip-reproduction-001.json
```

使用新的运行名称，执行文档所述的完整 Studio 训练、评估、渲染和导出流程。

## 动手命令：检查、冒烟测试、训练 · 2/2

### 03

工作目录：.

```
rlx/.venv-microduck/bin/python rlx/scripts/audit_backflip.py --run  
rlx/runs/studio/backflip/backflip-reproduction-001 --output rlx/artifacts/backflip-  
reproduction-001 --seeds 101,102,103,104,105,106,107,108
```

运行配对的展示、仅落地、初始化器、站立和零动作审计。

### 04




工作目录：duck-viewer

```
BACKFLIP_RUN=backflip-e2e-20260908-v5 node scripts/verify-backflip-studio.mjs
```

无需重新训练，验证保留的 V5 Studio 卡片、指导内容、评估面板、绑定来源的视频和响应式布局。

# 奖励：日志信号与真正的任务目标一致吗？





奖励记录：定义不同的信号，不能混为一谈



训练奖励是优化信号，不是验收标准。完整记录字段见 raw/<case>/。

# 损失：观察策略、价值估计与策略漂移



PPO 优化记录：原始数值，未经平滑



损失更低，不等于机器人技能更好。损失的符号和数值尺度取决于具体实现。

# 诊断：优化器的行为正常吗？

更新诊断：明确标注未记录的字段



熵、裁剪比例、解释方差和耗时都是诊断指标，不能单独构成通过或失败的证明。

## 指标矩阵：本次日志的数值审计 · 1/3

- 01 approximate\_kl: 首次 0.04450 → 最终 0.004050; 最小值 0.001318, 最大值 0.04450; 记录了 196 个样本。
- 02 clip\_fraction: 首次 0.2825 → 最终 0.04956; 最小值 0.004150, 最大值 0.2825; 记录了 196 个样本。
- 03 entropy: 首次 -29.23 → 最终 -29.23; 最小值 -29.23, 最大值 -29.23; 记录了 196 个样本。
- 04 explained\_variance: 首次 0.6132 → 最终 0.9215; 最小值 -0.8016, 最大值 0.9343; 记录了 196 个样本。

## 指标矩阵：本次日志的数值审计 · 2/3

05 mean\_loss: 首次 0.001169 → 最终 -0.003597; 最小值 -0.01114, 最大值 0.007229; 记录了 196 个样本。

06 mean\_raw\_return: 首次 3411 → 最终 2976; 最小值 2976, 最大值 3411; 记录了 41 个样本。

07 mean\_reward: 首次 0.03612 → 最终 0.03421; 最小值 0.03213, 最大值 0.03926; 记录了 196 个样本。

08 policy\_loss: 首次 -0.0009842 → 最终 -0.003618; 最小值 -0.01235, 最大值 0.005976; 记录了 196 个样本。

## 指标矩阵：本次日志的数值审计 · 3/3

09

value\_loss: 首次 0.002153 → 最终 0.00002170; 最小值 0.00001931, 最大值 0.002153; 记录了 196 个样本。

## 验证：查看结果前先定义成功标准 · 1/3

01

冒烟测试配置仅是四次转移的流水线检查，不是技能证据。

02

要求确定性评估报告每个完整的请求 episode 回合；拒绝不完整、非有限值、释放后仍受辅助、不满足支撑条件或失败的种子。

03

分别检查 600 步三阶段门槛和 600 步仅落地门槛。

04

在认可 PPO 落地行为前，确认 `assist_after_release_steps` 为零。

## 验证：查看结果前先定义成功标准 · 2/3

05 确认接管时旋转至少为 5.8 rad，且接管前 PPO 连续稳定记录达到 10 个样本。

06 确认仅落地的最后 100 个样本满足物理稳定性阈值；仅陀螺仪读数低并不充分。

07 逐个种子比较最终策略与初始化器的原始落地回报，并在固定动作噪声下重复评估，然后才能声称 PPO 有所改进。

08 检查 rollout MP4 和接触表中的空中旋转、落地接触、控制器阶段标签和最终稳定站立。

## 验证：查看结果前先定义成功标准 · 3/3

09

验证 ONNX 61-to-14 契约和 PyTorch/ONNX 动作一致性，以及策略和站立策略的哈希来源。

## 结果：实际测量到了什么？ · 1/3

- 01 事实：保留的 V5 默认三阶段评估通过了 16 个，共 16 个完整的 600 步展示 episode 回合。| 来源：rlx/runs/studio/backflip/backflip-e2e-20260908-v5/evaluation.json
- 02 事实：独立审计通过了 8 个，共 8 个展示 episode 回合，使用种子 801-808。| 来源：rlx/artifacts/backflip-e2e-20260908-v5/report.md
- 03 事实：移除站立策略接管后，最终 PPO actor 策略网络通过了 7 个，共 8 个仅落地 episode 回合；种子 808 未能保持最后全部 100 个样本。| 来源：rlx/artifacts/backflip-e2e-20260908-v5/report.md
- 04 事实：配对的仅落地平均原始回报从初始化器的 3409.02 退化到最终 actor 策略网络的 2978.57，差值为 -430.449 或 -12.63 百分比；有 0 个种子改善，共 8 个。| 来源：rlx/artifacts/backflip-e2e-20260908-v5/report.md

## 结果：实际测量到了什么？ · 2/3

- 05 事实：零动作通过了 0 个，共 8 个仅落地 episode 回合，尽管最终陀螺仪读数接近零；平均最终高度约为 0.0316 m，直立投影约为 0.1351。| 来源：rlx/artifacts/backflip-e2e-20260908-v5/report.md
- 06 事实：最终和初始化 ONNX 一致性的最大绝对动作误差为  $9.53674e-07$ ，且 61-input/14-output 契约通过。| 来源：rlx/artifacts/backflip-e2e-20260908-v5/report.md
- 07 事实：第一次 PPO 更新记录了 mean\_loss 0.0011691017134580761、policy\_loss - 0.0009841816499829292、value\_loss 0.002153283334337175、approximate\_kl 0.04449799966823775 和 clip\_fraction 0.282470703125。| 来源：rlx/runs/studio/backflip/backflip-e2e-20260908-v5/training-metrics.jsonl

## 结果：实际测量到了什么？ · 3/3

09

事实：env\_steps 401408 时的最终 PPO 更新记录了 mean\_loss -0.0035966151881439146、policy\_loss -0.003618316142819822、value\_loss 0.000021701008108720998、approximate\_kl 0.004050072617246769、clip\_fraction 0.049560546875 和 explained\_variance 0.9215395247283621。| 来源：rlx/runs/studio/backflip/backflip-e2e-20260908-v5/training-metrics.jsonl

10

事实：辅助展示通过了物理门槛，但扩展审计结论为 FAIL，因为 PPO 改进和所有种子独立落地成功这两项均不成立。| 来源：rlx/artifacts/backflip-e2e-20260908-v5/audit.json

## 观看已保存的真实仿真轨迹



播放前

预测一个成功信号和一个失败信号。

播放后

这个片段能支持哪些结论？哪些问题仍未检验？

已保存的 12.0 s MP4 • 在 PowerPoint 幻灯片放映中单击 • 备用：videos/backflip-rollout.mp4

## 局限与失败分析 · 1/2

01 这不是无辅助的学习后空翻。仿真器中的辅助器提供了大量起跳能量和旋转。

02 最终站立不由 PPO 负责；alpha\_stand.onnx 仅在 PPO 落地门槛通过后接管。

03 精确教师迁移意味着落地能力并非从零开始学习。

04 V5 物理展示成功不能证明 PPO 有所改善；配对的仅落地回报出现退化，且一个独立落地种子失败。

## 局限与失败分析 · 2/2

05 奖励可以为直立的空中姿态评分；触地和支撑由单独的物理门槛强制检查。

06 保留的运行关闭了随机化、噪声、延迟和随机 yaw。

07 导出的 backflip.onnx 只是落地阶段的 actor策略网络，不是完整控制器，也不代表获得硬件部署许可。

08 没有任何结果能够证明真机安全性、执行器可行性或仿真到现实的鲁棒性。

## 学生实验：只改一个变量，保留验收标准 · 1/3

- 01 绘制三列时间线，将每个起跳、落地和站立动作分别归属于辅助器、PPO actor策略网络或预训练站立策略。
- 02 使用观测表，识别哪些奖励输入可由 actor策略网络观测，哪些验收检查属于评估器的特权信号。
- 03 计算 PPO 批大小、每次更新的优化器步骤数，以及 401,408 次转移中完整更新的次数。
- 04 根据六个项的权重重新计算奖励的上界和下界。

## 学生实验：只改一个变量，保留验收标准 · 2/3

- 05 比较第一次和最后一次更新的字段，然后解释为什么更小的损失或 KL 不能证明落地表现更好。
- 06 使用审计表计算一个种子的配对百分比变化，并与汇总的 -12.63 百分比结果比较。
- 07 检查 ep0.mp4，并列出具能够区分辅助起跳、PPO 落地和站立策略接管的视觉证据。
- 08 设计固定噪声的配对评估，保持物理门槛不变，并检验后继策略是否改善了初始化器。

## 学生实验：只改一个变量，保留验收标准 · 3/3

09

写一句有证据支持的结论，再写一句属于过度声称的结论。

# 提交一个完整实验，而不只是一段视频

- 01 训练前：写下一个假设、要修改的参数、固定的基线、随机种子列表、验收标准，以及时间与转移数预算。
- 02 训练中：保存准确命令、环境版本、初始化方式、检查点，以及原始奖励、损失和 KL 指标。不得覆盖已有的参考运行。
- 03 训练后：使用相同随机种子评估冻结的导出策略；提交全部失败案例、汇总指标、完整轨迹视频和可追溯来源的结果表。
- 04 评分标准 / 10：可复现性 2；环境与奖励解释 2；PPO 与指标解读 2；如实验验证 2；一个有证据依据的后续实验 2。

# 来源索引与延伸学习 · 1/2

01

`microduck_local/AGENTS.md`

02

`docs/student-book/microduck-lab-student-book.md`

03

`docs/backflip-showcase/REPORT.md`

04

`docs/backflip-showcase/recipe.json`

## 来源索引与延伸学习 · 2/2

05

`docs/microduck-training-student-book/chapters/02a-ppo-code-lab.md`

06

`docs/microduck-training-student-book/chapters/02b-gae-workshop.md`

07

`scripts/scenarios/README.md`

08

`README.md`