


实验 06

篮球平衡

篮球：盲式循环平衡，而非转向

环境设计 · PPO · 如实验证

构建 → 训练 → 验证 → 讲解



你将构建什么？现有证据说明了什么？

- 01 用途：讲授循环策略状态、actor 策略网络热启动、物理辅助课程以及诚实的任务分解。保留的策略展示了在可自由移动的篮球上无辅助持续保持平衡，但尚未掌握按指令滚动和一般转向。
- 02 学习目标：描述场景，解释观测到动作的映射和奖励，追踪一次 PPO 更新，运行有限预算实验，并用证据支撑评估结论。
- 03 展示的结果是保持平衡，而不是维持静止的世界坐标位置、按指令滚动或转向。
- 04 适用范围：本地 MuJoCo 仿真。请勿将课堂产物直接部署到实体机器人；硬件迁移需要独立且经过验证的流程。

材料与准备条件 · 1/3

01 采用 CPU BAM 执行器和 50 Hz 策略控制的 Microduck 全碰撞 MuJoCo 模型

02 一个可自由移动的篮球球体，半径 0.12 m，质量 0.62 kg

03 microduck-playground/src/mjlab_microduck/robot/assets/basketball/basketball.obj 和 basketball.png，用作不参与碰撞的视觉网格与纹理

04 microduck-playground/artifacts/basketball/checkpoint.pt 和 policy.onnx，作为经过哈希验证的 b11 源 actor 策略网络

材料与准备条件 · 2/3

- 05 `rlx/rlx/environments/basketball.py`, 用于场景物理、辅助、奖励、终止条件和指标
- 06 `rlx/rlx/models/basketball.py`, 用于 LSTM256 actor 策略网络、全新 critic 价值网络、循环 ONNX 导出和一致性测试
- 07 `rlx/examples/ppo_microduck_basketball.py`, 用于本地循环 PPO 近端策略优化续训
- 08 `rlx/scripts/eval_basketball_local.py`, 用于确定性的首次跌倒评估和渲染

材料与准备条件 · 3/3

09

rlx/runs/studio/basketball/basketball-balance-01/, 用于保留的 Studio 策略、评估和预览

10

rlx/artifacts/basketball-local-20260910/, 用于 102,400 步固定指令训练记录

环境与策略接口约定 · 1/3

- 01 物理球体中心初始位于 $z=0.121$ m。机器人根部初始位于 $z=0.368$ m，在球顶附近保持直立；本任务不教授爬上篮球或从地面恢复。
- 02 物理步长为 0.005 s，每个动作包含四个子步，因此控制间隔为 0.02 s，策略频率为 50 Hz。
- 03 观测约定：float32[61]。索引 0:3 为躯干角速度；3:6 为投影重力；6:20 为关节偏移；20:34 为滞后一拍的关节速度；34:48 为上一个原始动作；48:51 为速度指令；51:61 为零填充。
- 04 动作约定：14 个关节目标偏移。实际目标为默认姿态加 $\text{clip}(\text{action}, -4, 4)$ ；观测保留上一个原始动作。

环境与策略接口约定 · 2/3

- 05 actor 策略网络不会接收球的位置、速度、旋转、接触、半径或世界坐标位置信号。它是盲式循环 actor 策略网络，只能通过本体感知历史推断动力学。
- 06 循环 ONNX 输入为 obs [1,61]、h_in [1,1,256] 和 c_in [1,1,256]；输出为 actions [1,14]、h_out [1,1,256] 和 c_out [1,1,256]。
- 07 隐藏状态和细胞状态会跨普通步骤及指令变化延续，并在试验、回合、策略、环境或恢复边界处重置。
- 08 物理辅助阶梯的 hold 级别为 1、0.5、0.25、0.1、0.03 和 0。它只通过仿真施加恢复力和恢复力矩；奖励保持不变。

环境与策略接口约定 · 3/3

09

保留的固定指令运行在 hold 0 且课程关闭的条件下训练。评估始终强制 hold 0，并且绝不会自动重置失败的试验。

10

直接评估采用 60 s、3,000 步、种子 101/202/303、随机初始偏航角、零指令和 0.15 m/s 前进指令，不施加推力、无观测噪声，也不进行质量/摩擦力域随机化。

案例构建流程：以证据形成验证闭环



失败也是数据：每次只改变一个因素，重新训练，并使用相同的验收标准。

逐步构建本案例 · 1/3

- 01 加载源 actor 策略网络之前，验证所提供 b11 检查点和 ONNX 的哈希。
- 02 构建自由球 MuJoCo 场景，其中包含参与碰撞的球体，以及单独的无质量、不参与碰撞的视觉网格。
- 03 在球顶附近重置机器人，并将循环隐藏状态和细胞状态清零。
- 04 迁移成熟的循环 actor 策略网络并冻结其观测归一化器；初始化全新的 61 输入前馈 critic 价值网络和全新的 Adam 优化器。

逐步构建本案例 · 2/3

- 05 按时间和环境收集完整的循环采样轨迹，保留初始隐藏/细胞张量和回合开始掩码。
- 06 在每个 PPO 近端策略优化训练轮次中回放完整的有序循环序列；不要将观测作为相互独立的行进行打乱。
- 07 在目标值 0.02 处应用 KL 提前停止，保存中间检查点，导出循环 ONNX，并在一致性比较期间测试一次状态重置。
- 08 将零指令平衡和按指令向前滚动作为不同类别分别评估。

逐步构建本案例 · 3/3

09

每次试验都延续循环状态，直到首次跌倒或恰好达到 3,000 步；不要用自动重置掩盖失败。

10

检查支撑、倾斜、根部偏移、球移动距离、球旋转、定向进展、速度跟踪、辅助和接触漏洞。

11

撰写课堂结论之前，同时检查零指令平衡视频和失败的前进指令滚动视频。

PPO：改进策略，同时避免盲目迈出过大一步

$$\text{ratio} = \pi_{\text{new}}(a \mid o) / \pi_{\text{old}}(a \mid o)$$

最大化 $\text{mean}[\min(\text{ratio} \times A, \text{clip}(\text{ratio}, 1 - \epsilon, 1 + \epsilon) \times A)]$

策略网络（Actor）：选择关节动作。价值网络（Critic）：估计未来折扣奖励。

A 表示优势； ϵ 表示裁剪范围。每个采样批次的旧策略对数概率在更新时保持不变。

沿着一次轨迹采样，理解学习器的处理过程

- 01 使用当前随机策略采集观测、采样动作、旧策略对数概率、价值估计、奖励以及回合边界标记。
- 02 计算时序差分残差和广义优势估计（GAE）。真正终止时，后续价值为零；超时截断时，可以使用保存的最终观测进行价值自举。
- 03 在重置边界切断优势递推。不得使用下一回合的初始观测，对上一回合的超时状态进行价值自举。
- 04 重复使用同一批数据进行 PPO 小批次更新，再采集新的同策略数据。评估时导出确定性策略网络及其观测变换。

纸笔练习：计算样本数与裁剪目标

- 01 教学算例，并非本次实验：16 个环境 $\times$ 128 步 = 每次采样得到 2,048 条新转移。四轮优化重复使用这些转移，并不会产生 8,192 条新样本。
- 02 当 $\epsilon = 0.2$ 、 $\text{ratio} = 1.4$ 、 $A = +2$ 时： $\min(2.8, 2.4) = 2.4$ 。在求平均和加入其他损失项之前，被最小化的策略项为 -2.4 。
- 03 保持相同的 ratio ，令 $A = -2$ ： $\min(-2.8, -2.4) = -2.8$ 。请解释：优势符号改变后，裁剪为何呈现不对称效果？
- 04 在仓库根目录运行：`python3 docs/microduck-training-student-book/learning_lab.py --gae`。这是确定性的算术练习，不会训练新策略。

奖励设计：智能体因何获得奖励？ · 1/3

- 01 名称：linear_tracking | 权重：1 | 符号：奖励 | 定义： $\exp(-\text{sum}((\text{body_linear_velocity_xy} - \text{command_xy})^2) / 0.1)$
- 02 名称：yaw_tracking | 权重：0.5 | 符号：奖励 | 定义： $\exp(-(\text{gyro_z} - \text{command_yaw})^2 / 0.5)$
- 03 名称：upright | 权重：1 | 符号：奖励 | 定义： $\exp(-\text{sum}(\text{projected_gravity_xy}^2) / 0.09)$
- 04 名称：centered | 权重：2 | 符号：奖励 | 定义： $\exp(-\text{sum}(\text{horizontal trunk-to-ball offset}^2) / 0.0016)$

奖励设计：智能体因何获得奖励？ · 2/3

- 05 名称：feet_on_ball | 权重：1 | 符号：奖励 | 定义： $\text{mean}(\exp(-\text{foot-to-ball surface gap squared} / 0.0004))$
- 06 名称：height | 权重：1 | 符号：奖励 | 定义： $\exp(-(\text{relative trunk height} - \text{ball radius} - 0.125) \text{ squared} / 0.0009)$
- 07 名称：ball_speed_penalty | 权重：0.05 | 符号：惩罚 | 定义： $-\min(\text{sum}(\text{ball horizontal velocity squared}), 100)$
- 08 名称：angular_velocity_penalty | 权重：0.05 | 符号：惩罚 | 定义： $-\min(\text{sum}(\text{trunk roll/pitch angular velocity squared}), 100)$

奖励设计：智能体因何获得奖励？ · 3/3

09

名称：action_rate_penalty | 权重：0.2 | 符号：惩罚 | 定义： $-\min(\text{sum}((\text{last_action} - \text{previous_action})^2), 100)$

10

名称：reward_scale | 权重：0.02 | 符号：时间缩放 | 定义：求和前，每个加权项都乘以 CTRL_DT=0.02；所有 hold/课程级别均使用相同权重。

已记录的训练配置 · 1/2

- 01 配置：warm_start | 值：b11 第 6999 次迭代的 actor 策略网络、冻结的归一化器、全新的本地 critic 价值网络和全新的 Adam 优化器；并非恢复上游优化器
- 02 配置：fixed_command_run | 值：102,400 次本地转移，来自 100 次更新 x 8 个环境 x 128 步，指令 [0.15,0,0]，种子 42
- 03 配置：optimizer | 值：学习率 $2e-6$ ，最多 5 个循环回放训练轮次，目标 KL 0.02，最大梯度范数 1.0
- 04 配置：ppo_objective | 值：gamma 0.99，GAE lambda 0.95，clip 系数 0.2，value 系数 1.0，entropy 系数 0.01，归一化优势

已记录的训练配置 · 2/2

- 05 配置: exploration_and_environment | 值: 初始动作标准差 0.03, BAM 执行器, hold 0, 课程关闭, 推力关闭, 观测噪声关闭, 域随机化关闭
- 06 配置: checkpointing | 值: 在第 25、50 和 75 次更新时保存中间产物; 最终为第 100 次更新; actor 策略网络参数 L2 变化 0.042958568781614304
- 07 配置: telemetry_fields | 值: update; loss; policy_loss; value_loss; entropy; gradient_norm; approx_kl; epochs_completed; kl_early_stop; hold_min; hold_max; completed_episodes
- 08 配置: evidence_gap | 值: Studio 目录没有独立训练轨迹。图表使用归档的源适配摘要 (100 次 PPO 近端策略优化更新), 其检查点 SHA-256 与导入的 Studio 检查点完全匹配。未保留历史训练奖励序列。

实操命令：检查、冒烟测试与训练 · 1/3

01

工作目录：.

```
rlx/.venv-microduck/bin/python -m pytest rlx/tests/test_basketball.py  
rlx/tests/test_basketball_policy.py rlx/tests/test_basketball_evaluation.py -q
```

运行场景、循环策略和评估诚实性约定测试。

02

工作目录：.

```
bash scripts/train-basketball.sh --output rlx/artifacts/basketball-smoke --num-envs 4 --  
updates 5 --steps 32 --learning-rate 2e-6
```

在全新输出目录中运行文档所述的五次更新训练冒烟测试。

实操命令：检查、冒烟测试与训练 · 2/3

03

工作目录：.

```
bash scripts/train-basketball.sh --output rlx/artifacts/basketball-training --num-envs 8 --updates 100 --steps 128 --learning-rate 2e-6 --save-interval 25 --command .15 0 0
```

运行文档所述的无辅助固定前进指令本地适配。

04

工作目录：.

```
rlx/.venv-microduck/bin/python rlx/scripts/eval_basketball_local.py --policy rlx/artifacts/basketball-training/policy.onnx --output rlx/artifacts/basketball-evaluation --seconds 60 --seeds 101 202 303 --command 0 0 0 --command .15 0 0 --render
```

分别评估并渲染静止平衡和按指令滚动。

实操命令：检查、冒烟测试与训练 · 3/3

05

工作目录：duck-viewer

`npm run dev`

打开 Studio，检查 `basketball-balance-01`，其中每个机器人都有独立的循环状态。

奖励：日志信号与真正的任务目标一致吗？

奖励记录：定义不同的信号，不能混为一谈

平均回合回报 / mean_raw_return


未记录
不编造缺失数值

未记录字段：mean_raw_return, mean_reward, mean_episode_length, episode_count

归档的源适配；与导入检查点的哈希完全匹配。未保留历史奖励曲线。

损失：观察策略、价值估计与策略漂移


PPO 优化记录：原始数值，未经平滑



归档的源适配；与导入检查点的哈希完全匹配。未保留历史奖励曲线。

诊断：优化器的行为正常吗？

更新诊断：明确标注未记录的字段



归档的源适配；与导入检查点的哈希完全匹配。未保留历史奖励曲线。

指标矩阵：本次日志的数值审计 · 1/2

- 01 approx_kl: 初始 0.08338 → 最终 0.01402; 最小 0.003539, 最大 0.08338; 100 个记录样本。
- 02 entropy: 初始 -29.23 → 最终 -29.14; 最小 -29.23, 最大 -29.14; 100 个记录样本。
- 03 kl_early_stop: 初始 1.000 → 最终 0.000; 最小 0.000, 最大 1.000; 100 个记录样本。
- 04 loss: 初始 1.660 → 最终 1.619; 最小 1.310, 最大 1.753; 100 个记录样本。

指标矩阵：本次日志的数值审计 · 2/2

05

policy_loss：初始 $-7.637e-8$ → 最终 -0.01592 ；最小 -0.02564 ，最大 0.003599 ；100 个记录样本。

06

value_loss：初始 1.368 → 最终 1.343 ；最小 1.037 ，最大 1.461 ；100 个记录样本。

验证：查看结果前先定义成功标准 · 1/3

01 训练前验证源检查点和 ONNX SHA256；拒绝任意未经验证的源文件。

02 检查观测槽位 51:61 是否保持为零，以及 actor 策略网络是否未接收显式球状态。

03 确认循环隐藏/细胞状态会在正常步骤间延续，并恰好在回合边界处重置。

04 要求循环 PyTorch/ONNX 在 40 步内保持一致，并在第 20 步重置状态。

验证：查看结果前先定义成功标准 · 2/3

- 05 在 hold 为零且无自动重置的条件下，按完整 3,000 步首次跌倒时域评估每次试验。
- 06 分别对 sustained_balance、controlled_rolling 和 learned_success 进行分类。
- 07 要获得平衡判定，要求机器人不接触地面、无非足部球体支撑、足部与球充分接触、倾斜和偏移受限且辅助为零。
- 08 对于向前滚动，还要求沿指令方向的有符号进展至少为 3.15 m，线速度跟踪 MAE 不超过 0.09 m/s，偏航跟踪 MAE 不超过 0.5 rad/s，并有充分的物理球体旋转。

验证：查看结果前先定义成功标准 · 3/3

09

检查原始 MP4，而不要只依赖稀疏的接触表帧或旋转纹理。


结果：实际测量了什么 · 1/2

- 01 事实：全部 6 次直接 60 秒试验均存活：种子 101、202 和 303 均在零指令和 0.15 m/s 前进指令下完成试验。| 来源：docs/basketball-showcase/evidence/evaluation.json
- 02 事实：全部 6 次试验均满足 sustained-balance 标准，但有 0/3 次前进指令试验满足 controlled-rolling 标准；汇总报告为 passed=false。| 来源：docs/basketball-showcase/evidence/evaluation.json
- 03 事实：最低足部-球体接触比例为 0.9993333333333333，即 99.93333333333332 百分比，最大倾斜为 4.733669151434107 度。| 来源：docs/basketball-showcase/evidence/evaluation.json
- 04 事实：三次前进指令的有符号进展值分别为 1.299956021320378 m、0.3004973917973738 m 和 0.35659880459696325 m，均低于 3.15 m 门槛。| 来源：docs/basketball-showcase/evidence/evaluation.json

结果：实际测量了什么 · 2/2

- 05 事实：三次 0.15 m/s 试验的平均前进跟踪 MAE 为 0.13764476597849953 m/s，高于 0.09 m/s 门槛。
| 来源：docs/basketball-showcase/evidence/evaluation.json
- 06 事实：固定指令运行增加了 102,400 次转移，使 actor 策略网络参数的 L2 距离变化 0.042958568781614304，并以最大循环一致性误差 $1.430511474609375e-06$ 完成导出。| 来源：rlx/artifacts/basketball-local-20260910/summary.json
- 07 事实：最终更新记录了 loss 1.6185429096221924、policy_loss -0.015916798263788223、value_loss 1.343021035194397、entropy -29.143863677978516、approximate_kl 0.014023307710886002 和 epochs_completed 5。| 来源：rlx/artifacts/basketball-local-20260910/summary.json
- 08 事实：保留的 Studio 适配器另行评估种子 101-103，仍报告 6/6 次 sustained balance，且有 0/3 次按指令滚动通过。| 来源：rlx/runs/studio/basketball/basketball-balance-01/evaluation.json

观看已保存的真实仿真轨迹



播放前

预测一个成功信号和一个失败信号。

播放后

这个片段能支持哪些结论？哪些问题仍未检验？

已保存 60.0 s MP4 • 在 PowerPoint 幻灯片放映中单击 • 备用：videos/basketball-rollout.mp4

局限与失败分析 · 1/3

- 01 展示的结果是保持平衡，而不是维持静止的世界坐标位置、按指令滚动或转向。
- 02 当前 Studio 适配器未评估横向和偏航转向，因此完整技能成功按保守原则判定为失败。
- 03 机器人从球上开始；登上篮球、从地面恢复以及不同表面之间的转移不属于本任务。
- 04 actor 策略网络是热启动的成熟 b11 策略，并非由本地 102,400 步运行从头训练的策略。

局限与失败分析 · 2/3

- 05 本地 critic 价值网络和优化器是全新的，因此这并非上游 GPU 训练状态的精确续训。
- 06 损失图表是归档的源适配诊断，并非新的 Studio 训练运行。导入的检查点哈希匹配；ONNX 文件经过重新导出。历史训练奖励仍不可用。
- 07 这六次标称本地试验省略了传感器噪声、质量/摩擦力随机化和推力；它们未复现上游压力测试组。
- 08 历史直接评估哈希早于当前源快照；该报告是保留的证据，并非全新且逐字节一致的重新运行。

局限与失败分析 · 3/3

09

不对硬件平衡或安全性作出任何声明。

学生实验：只改一个变量，保留验收标准 · 1/3

- 01 跟踪 h_{in}/c_{in} 到 h_{out}/c_{out} 的五个步骤，插入一次回合重置，并标出两个循环张量必须归零的位置。
- 02 根据环境数、采样轨迹步数和更新次数计算 102,400 次转移。
- 03 针对给定的单步状态，计算每个加权奖励贡献，包括最终的 0.02 控制时间缩放。
- 04 比较 `sustained_balance` 和 `controlled_rolling` 标准，并找出获得转向判定所需的额外测量。

学生实验：只改一个变量，保留验收标准 · 2/3

- 05 相对于 3.15 m 阈值绘制三个前进进展值，并解释为何肉眼可见的球体运动仍不足以通过。
- 06 检查零指令和前进指令视频，并标注支撑变化、漂移和相对相机的运动。
- 07 读取最终 PPO 近端策略优化损失记录，并解释为何其中的有限数值无法弥补历史奖励曲线的缺失。
- 08 提出一种滚动状态初始化课程，在保持评估和奖励权重不变的同时改变探索物理或生成位置。

学生实验：只改一个变量，保留验收标准 · 3/3

09

分别为源 b11 性能、本地固定指令适配和 Studio 回放撰写证据陈述。

提交一个完整实验，而不只是一段视频

- 01 训练前：写下一个假设、要修改的参数、固定的基线、随机种子列表、验收标准，以及时间与转移数预算。
- 02 训练中：保存准确命令、环境版本、初始化方式、检查点，以及原始奖励、损失和 KL 指标。不得覆盖已有的参考运行。
- 03 训练后：使用相同随机种子评估冻结的导出策略；提交全部失败案例、汇总指标、完整轨迹视频和可追溯来源的结果表。
- 04 评分标准 / 10：可复现性 2；环境与奖励解释 2；PPO 与指标解读 2；如实验验证 2；一个有证据依据的后续实验 2。

来源索引与延伸学习 · 1/2

01

`microduck_local/AGENTS.md`

02

`docs/student-book/microduck-lab-student-book.md`

03

`docs/basketball-bridge-book/chapters/en/03-ppo.md`

04

`docs/basketball-bridge-book/chapters/en/04-basketball.md`

来源索引与延伸学习 · 2/2

05

`docs/microduck-training-student-book/chapters/02a-ppo-code-lab.md`

06

`docs/microduck-training-student-book/chapters/02b-gae-workshop.md`

07

`scripts/scenarios/README.md`

08

`README.md`