


实验 07

悬索桥

悬索桥：值得研究的一次失败穿越

环境设计 · PPO · 如实验证

构建 → 训练 → 验证 → 讲解



你将构建什么？现有证据说明了什么？

- 01 用途：讲授移动支撑面仿真、特权指令生成、纯物理课程、热启动 PPO 近端策略优化、严格的接触式评估，以及对失败策略的科学报告。环境和流程可以运行，但保留的试验策略未完成一次被接受的穿越。
- 02 学习目标：描述场景，解释观测到动作的映射和奖励，追踪一次 PPO 更新，运行有限预算实验，并用证据支撑评估结论。
- 03 悬索桥穿越失败。部分进展和有效场景并不能证明已掌握所要求的技能。
- 04 适用范围：本地 MuJoCo 仿真。请勿将课堂产物直接部署到实体机器人；硬件迁移需要独立且经过验证的流程。

材料与准备条件 · 1/3

- 01 采用 XML 位置伺服器和标准 `alpha_walking.onnx` 引导策略的 Microduck MuJoCo 模型
- 02 一块自由木板，1.10 x 0.13 x 0.03 m，质量 0.45 kg
- 03 两个固定平台，每个尺寸为 0.60 x 0.48 x 0.24 m
- 04 四根空间肌腱缆索，刚度 320、阻尼 2.0、宽度 0.0015 m，并设有固定锚点

材料与准备条件 · 2/3

05 可见但不参与碰撞的门架立柱和横梁，以及用于检测失败的独立地面平面

06 rlx/rlx/environments/bridge.py，用于几何结构、指令器、辅助、接触、指标和课程

07 rlx/rlx/environments/bridge_evaluation.py，用于完整时域、接触验证的穿越门槛

08 rlx/rlx/models/bridge_bootstrap.py，用于精确迁移行走 actor 策略网络和归一化器

材料与准备条件 · 3/3

09

`rlx/examples/ppo_microduck_studio.py` 和 `scripts/train-bridge.sh`，用于训练、评估、渲染和导出

10

`rlx/runs/studio/bridge/bridge-studio-02/`，用于保留的 32,768 次转移试验和失败诊断视频

环境与策略接口约定 · 1/3

- 01 木板是初始中心位于 $(0,0,0.225)$ m 的 MuJoCo 自由刚体。四根物理肌腱将木板连接点与锚点相连，锚点位于 $x \pm 0.45$ m、 $y \pm 0.17$ m、 $z 0.77$ m。
- 02 标称木板横跨 $x=-0.55$ 到 0.55 m。起点和终点平台中心分别位于 $x=-0.85$ m 和 $x=0.85$ m，所有顶面均位于 $z=0.24$ m。
- 03 可见门架使用 $\text{contype}=0$ 和 $\text{conaffinity}=0$ 。它无法支撑或挽救机器人；只有肌腱、平台、木板和地面参与接触动力学。
- 04 物理仿真以 0.005 s 运行，每个 14 维动作指令包含四个子步，因此控制间隔为 0.02 s，频率为 50 Hz。

环境与策略接口约定 · 2/3

- 05 观测/动作约定保持为 float32[61] 到 14 个关节目标偏移。观测切片为角速度 0:3、投影重力 3:6、关节偏移 6:20、滞后关节速度 20:34、上一个动作 34:48、twist 指令 48:51、零 head 指令 51:55，以及零 body 指令 55:61。
- 06 actor 策略网络不会接收木板位置、速度、横滚角、俯仰角、缆索状态、世界坐标位置、桥面接触、穿越标志或辅助级别。
- 07 外部导航指令器使用世界坐标中的躯干 x/y 和朝向来发布普通机体坐标系 twist 指令。它给出标称 0.25 m/s 前进速度、横向修正 $\text{clip}(-1.2*y, -0.12, 0.12)$ ，以及偏航修正 $\text{clip}(-1.5*yaw_error, -0.6, 0.6)$ 。
- 08 当世界坐标 x 至少达到 0.80 m 时，指令器将期望前进速度设为零，同时保留横向和偏航修正。

环境与策略接口约定 · 3/3

09

纯物理辅助级别为 1.0、0.6、0.3、0.1 和 0.0。它们缩放施加在木板上的恢复力、调平力矩和阻尼，绝不施加在机器人上。

10

课程各阶梯还会改变声明的重置生成距离。奖励权重保持相同。评估和渲染在最终起始平台生成位置使用辅助 0。

11

一次被接受的穿越要求：从起点至少前进 1.60 m，此前足部接触过悬空木板，双足均位于终点平台，足部或身体均未接触地面，无非足部支撑，无辅助，未跌倒，并完成完整的 1,000 步时域。

案例构建流程：以证据形成验证闭环



失败也是数据：每次只改变一个因素，重新训练，并使用相同的验收标准。

逐步构建本案例 · 1/3

- 01 按照记录的尺寸构建自由木板、平台、四根肌腱、锚点、不参与碰撞的门架和用于检测失败的地面。
- 02 验证仅移动木板而不移动机器人时，actor 策略网络的 61 值观测不会变化。
- 03 加载 alpha_walking.onnx，精确迁移其 actor 策略网络和归一化器，检查动作一致性，冻结观测归一化，并创建全新的 critic 价值网络和优化器。
- 04 仅在训练时启用 bridge-curriculum，使早期采样轨迹能够采样稳定的木板和更近的生成位置。

逐步构建本案例 · 2/3

- 05 保持继承的运动奖励不变；不要添加世界坐标 x 进展奖励或 bridge-crossed 巨额奖励。
- 06 训练 4 个环境，每批完整运行 128 步，直到收集 32,768 次新转移。
- 07 导出 bridge.onnx，将冻结的归一化器融入标准原始 61 输入接口。
- 08 对 3 条并行通道各评估 1,000 步，使用种子 101，且无辅助、无随机化、无观测噪声、无动作延迟、无随机偏航角。

逐步构建本案例 · 3/3

09

分别跟踪重置产生的每次尝试和末尾不完整片段；不要将 3,000 次通道转移重新解释为三个完整的成功回合。

10

应用基于接触验证的穿越门槛，并保留失败回合、地面接触、缺失木板接触、进展和支撑计数。

11

渲染完整的 20 秒诊断视频并标记其中两次重置，避免将多次部分尝试展示为一次连续穿越。

PPO：改进策略，同时避免盲目迈出过大一步

$$\text{ratio} = \pi_{\text{new}}(a \mid o) / \pi_{\text{old}}(a \mid o)$$

最大化 $\text{mean}[\min(\text{ratio} \times A, \text{clip}(\text{ratio}, 1 - \epsilon, 1 + \epsilon) \times A)]$

策略网络（Actor）：选择关节动作。价值网络（Critic）：估计未来折扣奖励。

A 表示优势； ϵ 表示裁剪范围。每个采样批次的旧策略对数概率在更新时保持不变。

沿着一次轨迹采样，理解学习器的处理过程

- 01 使用当前随机策略采集观测、采样动作、旧策略对数概率、价值估计、奖励以及回合边界标记。
- 02 计算时序差分残差和广义优势估计（GAE）。真正终止时，后续价值为零；超时截断时，可以使用保存的最终观测进行价值自举。
- 03 在重置边界切断优势递推。不得使用下一回合的初始观测，对上一回合的超时状态进行价值自举。
- 04 重复使用同一批数据进行 PPO 小批次更新，再采集新的同策略数据。评估时导出确定性策略网络及其观测变换。

纸笔练习：计算样本数与裁剪目标

- 01 教学算例，并非本次实验：16 个环境 $\times$ 128 步 = 每次采样得到 2,048 条新转移。四轮优化重复使用这些转移，并不会产生 8,192 条新样本。
- 02 当 $\epsilon = 0.2$ 、 $\text{ratio} = 1.4$ 、 $A = +2$ 时： $\min(2.8, 2.4) = 2.4$ 。在求平均和加入其他损失项之前，被最小化的策略项为 -2.4 。
- 03 保持相同的 ratio ，令 $A = -2$ ： $\min(-2.8, -2.4) = -2.8$ 。请解释：优势符号改变后，裁剪为何呈现不对称效果？
- 04 在仓库根目录运行：`python3 docs/microduck-training-student-book/learning_lab.py --gae`。这是确定性的算术练习，不会训练新策略。

奖励设计：智能体因何获得奖励？ · 1/3

- 01 名称：track_lin_vel | 权重：2 | 符号：奖励 | 定义：对机体坐标系线速度与 twist_cmd 的指数跟踪，包括垂直速度误差
- 02 名称：track_ang_vel | 权重：2 | 符号：奖励 | 定义：对指令偏航角速度进行指数跟踪，并在跟踪误差中加入横滚/俯仰角速度代价
- 03 名称：upright | 权重：2 | 符号：奖励 | 定义： $\exp(-\text{sum}(\text{projected_gravity_xy squared}) / 0.05)$
- 04 名称：pose | 权重：1 | 符号：奖励 | 定义： $\exp(-\text{sum}(\text{leg joint offsets squared}) / 0.5)$

奖励设计：智能体因何获得奖励？ · 2/3

- 05 名称：head_pose | 权重：2 | 符号：奖励 | 定义：每个头部关节的 $\text{mean exp}(-(\text{head_error} / 0.5) \text{ squared})$
- 06 名称：feet_air_time | 权重：3 | 符号：奖励 | 定义：移动足部的腾空时间位于 0.125 s 和 0.300 s 之间时提供稠密奖励
- 07 名称：action_rate_penalty | 权重：全程调度，0.1 对应第 0 步、0.2 对应第 12000 步、0.4 对应第 18000 步、0.6 对应第 24000 步、0.8 对应第 30000 步、1.0 对应第 36000 步 | 符号：惩罚 | 定义： $-\text{weight} * \text{sum}((\text{last_action} - \text{previous_action}) \text{ squared})$
- 08 名称：ang_vel_xy_penalty | 权重：0.05 | 符号：惩罚 | 定义： $-0.05 * (\text{gyro_x squared} + \text{gyro_y squared})$

奖励设计：智能体因何获得奖励？ · 3/3

09

名称：bridge_specific_reward | 权重：0 | 符号：无 | 定义：不存在针对世界坐标 x、桥上进展、木板角度、缆索张力、终点接触或 bridge_crossed 的奖励。桥梁检查点元数据将 reward_weights 记录为空的覆盖对象。

已记录的训练配置 · 1/2

- 01 配置：transition_budget | 值：32,768 次新的 PPO 近端策略优化转移，4 个环境 x 128 步 x 64 次更新
- 02 配置：ppo_batch | 值：4 个环境、128 步、4 个小批次、2 个更新轮次
- 03 配置：optimizer | 值：Adam 学习率 $1e-5$ ，最大梯度范数 0.5，全新的优化器和全新按种子初始化的 critic 价值网络
- 04 配置：discount_and_objective | 值：gamma 0.99，GAE lambda 0.95，clip 系数 0.1，启用裁剪后的价值损失，value 系数 1.0，归一化优势

已记录的训练配置 · 2/2

05 配置：探索 | 取值：初始动作标准差 0.03，熵系数 0

06 配置：normalization_and_transfer | 值：精确迁移 alpha_walking actor 策略网络和归一化器；动作一致性最大绝对误差为 $1.0728836059570312e-06$ （共 32 个样本）；冻结观测归一化；关闭奖励归一化

07 配置：environment | 值：XML 执行器、虚拟后端、训练时开启 bridge curriculum、最大回合 20 s、种子 7、域随机化关闭、观测噪声关闭、动作延迟关闭、随机偏航角关闭

08 配置：telemetry_fields | 值：phase; env_steps; steps; seconds; optimizer_steps; mean_loss; policy_loss; value_loss; entropy; approximate_kl; clip_fraction; explained_variance; mean_reward; mean_raw_return; returns; lengths

实操命令：检查、冒烟测试与训练 · 1/3

01

工作目录：.

```
./scripts/train-bridge.sh train --bridge-curriculum --total-timesteps 32768 --num-envs 4 --num-steps 128 --num-minibatches 4 --backend dummy --no-domain-rand --no-obs-noise --no-action-delay --no-random-yaw --max-episode-s 20 --seed 7 --output-dir
```

rlx/runs/studio/bridge/my-bridge

在全新输出目录中运行文档所述的有界训练试验。

02

工作目录：.

```
./scripts/train-bridge.sh eval --backend dummy --num-envs 3 --seed 101 --policy  
rlx/runs/studio/bridge/my-bridge/bridge.onnx --eval-steps 1000 --max-episode-s 20 --no-domain-rand --no-obs-noise --no-action-delay --no-random-yaw
```

运行文档所述的无辅助完整时域穿越评估。

实操命令：检查、冒烟测试与训练 · 2/3

03

工作目录：duck-viewer

```
npm run dev
```

打开 Studio，检查保存的失败试验、评估详情和诊断渲染。

04

工作目录：.

```
bash restart-lab.sh --readiness-only
```

检查所有场景路由，但不要声称桥梁案例已通过其技能门槛。

实操命令：检查、冒烟测试与训练 · 3/3

05





工作目录：.

```
node scripts/verify-seven-cases.mjs
```

验证自定义桥梁场景、四根肌腱、平台、门架和七案例 UI 集成均已存在。

奖励：日志信号与真正的任务目标一致吗？





奖励记录：定义不同的信号，不能混为一谈



训练奖励是优化信号，不是验收标准。完整记录字段见 `raw/<case>/`。

损失：观察策略、价值估计与策略漂移



PPO 优化记录：原始数值，未经平滑



损失更低，不等于机器人技能更好。损失的符号和数值尺度取决于具体实现。

诊断：优化器的行为正常吗？

更新诊断：明确标注未记录的字段



熵、裁剪比例、解释方差和耗时都是诊断指标，不能单独构成通过或失败的证明。

指标矩阵：本次日志的数值审计 · 1/3

- 01 approximate_kl: 初始 0.5333 → 最终 0.01181; 最小 0.007837, 最大 0.6186; 64 个记录样本。
- 02 clip_fraction: 初始 0.7217 → 最终 0.2979; 最小 0.2666, 最大 0.7949; 64 个记录样本。
- 03 entropy: 初始 -29.23 → 最终 -29.22; 最小 -29.23, 最大 -29.22; 64 个记录样本。
- 04 explained_variance: 初始 0.001202 → 最终 0.05922; 最小 -0.06060, 最大 0.1143; 64 个记录样本。

指标矩阵：本次日志的数值审计 · 2/3

- 05 mean_loss: 初始 964.7 → 最终 992.4; 最小 840.4, 最大 1104; 64 个记录样本。
- 06 mean_raw_return: 初始 517.6 → 最终 1676; 最小 318.2, 最大 8254; 110 个记录样本。
- 07 mean_reward: 初始 7.171 → 最终 7.420; 最小 6.653, 最大 8.069; 64 个记录样本。
- 08 policy_loss: 初始 0.05633 → 最终 0.001741; 最小 -0.008248, 最大 0.2919; 64 个记录样本。

指标矩阵：本次日志的数值审计 · 3/3

09

value_loss：初始 964.7 → 最终 992.4；最小 840.4，最大 1104；64 个记录样本。

验证：查看结果前先定义成功标准 · 1/3

01 训练前确认标准 61 输入/14 输出 actor 策略网络约定和冻结归一化器的一致性。

02 验证门架 geom 不参与碰撞且无法形成隐藏支撑。

03 验证课程只向木板施力，并且绝不改变奖励权重。

04 在不使用 `--bridge-curriculum` 的条件下评估，并要求每个获得认可的步骤均满足 `bridge_assistance=0`。

验证：查看结果前先定义成功标准 · 2/3

- 05 要求每条通道恰好完成 1,000 步时域；截断的末尾片段不能通过。
- 06 要求至少前进 1.60 m，并且经过接触验证的 `bridge_crossed` 标志成立且双足均位于终点。
- 07 出现地面接触、非足部支撑、缺少悬空木板接触、跌倒或回合不完整时均判定失败。
- 08 检查 `recipe_metrics` 字段 `bridge_crossed`、`bridge_progress_m`、`bridge_assistance`、`bridge_contact_observed`、`feet_on_bridge`、`feet_on_end_platform`、`robot_floor_contact` 和 `nonfoot_support`。

验证：查看结果前先定义成功标准 · 3/3

09

观看完整 MP4 并统计重置次数；不要合并不同尝试的进展。

10

区分 `pipeline_passed=true` 与 `skill_status=failed`。

结果：实际测量到了什么？ · 1/3

- 01 事实：bridge-studio-02 恰好训练了 32,768 次新的 PPO 近端策略优化转移。| 来源：rlx/runs/studio/bridge/bridge-studio-02/result.json
- 02 事实：技能评估结果为 pipeline_passed=true，但 passed=false 且 skill_status=failed。| 来源：rlx/runs/studio/bridge/bridge-studio-02/evaluation.json
- 03 事实：在观察到的 11 次尝试和末尾片段中，记录到 0 次被接受的穿越和 0 个完成的 1,000 步回合。| 来源：rlx/runs/studio/bridge/bridge-studio-02/evaluation.json
- 04 事实：最佳桥上进展为 1.1749158752636413 m，低于 1.60 m 阈值，并且 feet_on_end_platform 的最大值为 0。| 来源：rlx/runs/studio/bridge/bridge-studio-02/evaluation.json

结果：实际测量到了什么？ · 2/3

05 事实：评估辅助始终恰好为零；bridge_assistance 的最小值、平均值和最大值均为 0。| 来源：rlx/runs/studio/bridge/bridge-studio-02/evaluation.json

06 事实：env_steps 512 时的第一次 PPO 近端策略优化更新记录了 mean_loss 964.7162933349609、policy_loss 0.05632817558944225、value_loss 964.6599655151367、approximate_kl 0.5332980752573349、clip_fraction 0.7216796875 和 explained_variance 0.0012020504251625264。| 来源：rlx/runs/studio/bridge/bridge-studio-02/training-metrics.jsonl

07 事实：env_steps 32768 时的最终 PPO 近端策略优化更新记录了 mean_loss 992.3935241699219、policy_loss 0.0017409028951078653、value_loss 992.3917770385742、approximate_kl 0.011814007302746177、clip_fraction 0.2978515625 和 explained_variance 0.05922189893301022。| 来源：rlx/runs/studio/bridge/bridge-studio-02/training-metrics.jsonl

08 事实：保留的 20 秒诊断视频包含两次明确重置以及之后在木板上的部分进展；它不是一次连续穿越。| 来源：docs/bridge-showcase/RESULTS.md


结果：实际测量到了什么？ · 3/3

09

事实：渲染 MP4 通过 SHA256

7386c84eb8065d2f4ac2b297ba5b082dc658648657e4190a9491872bab6e50a
6 绑定哈希。| 来源：rlx/runs/studio/bridge/bridge-studio-
02/render/evidence.json

观看已保存的真实仿真轨迹



播放前

预测一个成功信号和一个失败信号。

播放后

这个片段能支持哪些结论？哪些问题仍未检验？

已保存 20.0 s MP4 • 在 PowerPoint 幻灯片放映中单击 • 备用：videos/bridge-rollout.mp4

局限与失败分析 · 1/2

- 01 悬索桥穿越失败。部分进展和有效场景并不能证明已掌握所要求的技能。
- 02 导航指令器使用特权世界坐标位置和朝向，因此完整协议包含学习得到的 actor 策略网络之外的组件。
- 03 actor 策略网络看不到木板状态，只能通过 IMU、关节、上一个动作和生成的指令槽位进行适应。
- 04 该试验从 alpha_walking 热启动 actor 策略网络，并使用全新的 critic 价值网络和优化器，并非上游训练的精确续训。

局限与失败分析 · 2/2

- 05 课程完成情况尚未得到证实；32,768 次转移并不意味着已晋级到最终无辅助阶梯。
- 06 保留的评估关闭了随机化、噪声、延迟和随机偏航角，并且只使用三条向量化通道。
- 07 木板、摩擦力、肌腱和缆索数值是合理的仿真器参数，并非实测值或经过认证的施工方案。
- 08 不声称实现了硬件安全的穿越或仿真到现实结果。

学生实验：只改一个变量，保留验收标准 · 1/3

01

根据平台、木板和锚点坐标，按比例绘制桥梁侧视图。

02

根据 0.113 m 横向偏移和 0.545 m 垂直偏移计算标称缆索长度。

03

标出指令器的每个特权输入，以及实际传递给 61 维观测 actor 策略网络的每个值。

04

解释为何 `bridge_progress_m` 可用于评估，却有意不纳入奖励。

学生实验：只改一个变量，保留验收标准 · 2/3

05 计算 32,768 次转移运行的批大小、更新次数和优化器 minibatch 大小。

06 绘制第一次和最终更新的损失字段，并解释为何两者都不能证明完成了穿越。

07 读取 11 次评估尝试，并将每次失败分类为跌倒、时域不完整、缺少木板接触、地面接触或进展不足。

08 观看 ep0.mp4，为两次重置标注时间戳，并找出连续行进最远的一次尝试。

学生实验：只改一个变量，保留验收标准 · 3/3

09

设计一项物理/生成位置课程调整，同时保持奖励和最终评估门槛不变。

10

撰写一张结果幻灯片，在标题中明确说明失败，同时保留有用的环境与探索证据。

提交一个完整实验，而不只是一段视频

- 01 训练前：写下一个假设、要修改的参数、固定的基线、随机种子列表、验收标准，以及时间与转移数预算。
- 02 训练中：保存准确命令、环境版本、初始化方式、检查点，以及原始奖励、损失和 KL 指标。不得覆盖已有的参考运行。
- 03 训练后：使用相同随机种子评估冻结的导出策略；提交全部失败案例、汇总指标、完整轨迹视频和可追溯来源的结果表。
- 04 评分标准 / 10：可复现性 2；环境与奖励解释 2；PPO 与指标解读 2；如实验验证 2；一个有证据依据的后续实验 2。

来源索引与延伸学习 · 1/2

01

`microduck_local/AGENTS.md`

02

`docs/student-book/microduck-lab-student-book.md`

03

`docs/basketball-bridge-book/chapters/en/03-ppo.md`

04

`docs/basketball-bridge-book/chapters/en/05-bridge.md`

来源索引与延伸学习 · 2/2

05

`docs/microduck-training-student-book/chapters/02a-ppo-code-lab.md`

06

`docs/microduck-training-student-book/chapters/02b-gae-workshop.md`

07

`scripts/scenarios/README.md`

08

`README.md`