


实验 08

游泳鸭 绘图

彩色鸭绘画：成功的 brush-v2 反馈控制

环境设计 · PPO · 如实验证

构建 → 训练 → 验证 → 讲解



你将构建什么？现有证据说明了什么？

- 01 用例：MicroDuck 在 MuJoCo 中使用预先装入的自由画笔，绘制固定的四色游泳鸭。已发布的 brush-color-v2-03 ONNX 通过了要求的 40/40 个回合。讲授完整的教师数据、岭回归 BC、DAgger、锚定 PPO、导出和验证流水线。匹配的 BC 也通过了 40/40：PPO 保留了成功行为，并未证明有所改进。历史铅笔失败仍是独立证据。
- 02 学习目标：描述场景，解释观测到动作的映射和奖励，追踪一次 PPO 更新，运行有限预算实验，并用证据支撑评估结论。
- 03 现在已支持成功的固定模板仿真绘画。较早的铅笔实验并未被追溯改判为成功，新的 93/15 画笔契约也不能替代标准 61/14 部署。
- 04 适用范围：本地 MuJoCo 仿真。请勿将课堂产物直接部署到实体机器人；硬件迁移需要独立且经过验证的流程。

材料与准备条件 · 1/2

- 01 一个全碰撞 MicroDuck 仿真、画布和画架；14 个原始关节控制，外加一个仿真下颚动作。这是教学模型，不是硬件物料清单。
- 02 一支自由画笔通过 pencil_free 关节夹持在上、下喙垫之间。它是预先装入的，并未焊接到头部；自主拾取不属于本案例范围。
- 03 一个被动柔顺接触笔簇：球体半径 1.0 mm、质量 0.00003 kg，bristle_compression 行程 -3.0 至 0.3 mm。三根装饰性刷毛和一个金属箍仅用于视觉呈现，并非各自独立的柔性接触刷毛。
- 04 一个被动弹簧，刚度 25 N/m、阻尼 0.32 N s/m、armature 0.001 kg，默认夹持摩擦系数 1.2。它增加的是柔顺性，而不是第十六个电机。

材料与准备条件 · 2/2

05

四个实体颜料槽：金色、橙色、炭黑色和蓝色；另有一个不参与接触的调色盘背板。笔尖接触时加载离散颜料；仿真不包含流体混合、清洗或残余颜料动力学。

06

现有 CPU Python 环境包含 MuJoCo、Torch、Stable-Baselines3、Gymnasium、NumPy、ONNX、ONNX Runtime、Pillow 和 FFmpeg。使用 `rlx/.venv-microduck/bin/python`；源代码/模型兼容性比未经验证的软件包升级更重要。

07

保留的产物：final-seed11 教师数据集及侧车文件；brush-color-v2-03 已归档源代码包、训练元数据、BC/PPO 检查点、冻结的 ONNX 文件、评估和实际接触视频。仅含幻灯片的 ZIP 并不包含所有权重或训练依赖项。

环境与策略接口约定 · 1/3

- 01 当前契约：microduck-brush-v2，93 个观测和 15 个动作，simulation_only 且 hardware_compatible=false。历史铅笔使用 microduck-drawing-v1 83/15。两者都不能热切换到标准 61/14 行走部署中。
- 02 观测 0:61 保留 IMU 角速度、投影重力、14 个相对关节位置、先前的关节速度/动作以及清零的预留命令槽。观测 61:83 增加嘴部状态、笔尖/目标几何关系、速度、落笔请求和接触力。
- 03 画笔尾部 83:87 = 已加载颜色 one-hot；87:91 = 计划颜色 one-hot；91 = 以毫米为单位的压缩量；92 = 轨迹模式除以 2。当前 actor 不使用 83:93：颜色规划和漏蘸恢复并非学习所得。
- 04 动作 0:14 控制原始关节；action[14] 映射为 $\text{mouth_target} = 0.24 + 0.36 * \text{action}[14]$ 。结构化头部 actor 预测每步限制在 0.025 以内的增量，并且仅在输出时将其加到前一个动作上。

环境与策略接口约定 · 2/3

- 05 头部特征组合位置、目标误差、画笔方向、接触力和二次交互项。踝关节使用线性重力/角速度反馈；其他身体关节和下颌学习常量偏移。这是结构化的学习型反馈策略，不是不受约束的图像到动作网络。
- 06 物理时间步 0.002 s 对应 500 Hz；10 个子步形成 0.020 s 的控制周期，即 50 Hz。完整参考轨迹包含 5,998 个控制步，实测为 119.96 s，尽管命令预算为 120 s。
- 07 只有笔尖/颜料槽的实际作用力高于 0.0001 N 时才会加载颜料。画布标记使用 MuJoCo 中笔尖的实际接触和当前已加载颜色，而不是将参考像素粘贴到画布上。
- 08 固定鸭子图案、颜色分配、笔画顺序以及接近/蘸取/提笔目标均由人工设计。学习得到的电机控制器在运行时无需雅可比教师即可遵循该计划。本案例不声称具备相机、图像识别或任意视觉构图能力。

环境与策略接口约定 · 3/3

09

成功结果在十种独立配置上进行评估，每种配置使用四个种子。重置扰动测试的是有界域；一张漂亮的渲染图并不等同于 40 回合验收结果。

案例构建流程：以证据形成验证闭环



失败也是数据：每次只改变一个因素，重新训练，并使用相同的验收标准。

逐步构建本案例 · 1/2

- 01 首先保留历史事实：drawing-pilot-01 和 drawing-refinement-02 各使用了 32,768 个 PPO transitions, 且均未通过铅笔验收。它们的教师可行性视频并不是成功的学习策略。
- 02 诊断发现一个已确认的配置缺陷：预期的 initial_std=0.005 在 BC 后被重置为实际生效的 0.02。两个历史 PPO 策略也都偏离了 BC。这些观察结果不能证明所有失败都源于同一个原因。
- 03 构建独立的 brush-v2 契约，包含柔顺接触、实体颜色槽和结构化动作增量 actor。多项变更同时发生，因此不能将全部改进归因于 PPO 或仅归因于画笔柔顺性。
- 04 在收集数据前归档训练源代码。使用数据种子 11 时，解析雅可比教师提供八个 5,998 步回合：共 47,984 条初始标注观测/动作。

逐步构建本案例 · 2/2

- 05 使用 $\text{ridge}=0.01$ 拟合岭回归 BC。在两轮 DAgger 中重新标注学生访问的状态并再次拟合；数据集大小依次变为 47,984、77,974 和 105,858。这些是监督拟合记录，不是新的 PPO transitions。
- 06 使用训练种子 101、较小的逐动作噪声和 $\text{learning_rate}=1\text{e}-7$ 热启动 PPO。收集 49,152 个真正的同策略 transitions；每次更新后，在保存的 BC/DAgger 锚点观测上评估确定性动作漂移。
- 07 仅当最大漂移为有限值且 ≤ 0.00025 时接受更新；否则恢复策略参数和优化器状态。导出不可变的确定性 PPO 和匹配 BC ONNX，使用静态 93-input/15-output 接口。
- 08 对两个模型运行完全相同的独立验收套件，验证源代码/模型哈希，检查所有失败和负对照，然后渲染同一个 PPO ONNX。最终门槛通过；本课程不会重新运行训练。

PPO：改进策略，同时避免盲目迈出过大一步

$$\text{似然比 } \text{ratio} = \pi_{\text{new}}(a \mid o) / \pi_{\text{old}}(a \mid o)$$

最大化 $\text{mean}[\min(\text{ratio} \times A, \text{clip}(\text{ratio}, 1 - \epsilon, 1 + \epsilon) \times A)]$

策略网络（Actor）：选择关节动作。价值网络（Critic）：估计未来折扣奖励。

A 表示优势； ϵ 表示裁剪范围。每个采样批次的旧策略对数概率在更新时保持不变。

沿着一次轨迹采样，理解学习器的处理过程

- 01 使用当前随机策略采集观测、采样动作、旧策略对数概率、价值估计、奖励以及回合边界标记。
- 02 计算时序差分残差和广义优势估计（GAE）。真正终止时，后续价值为零；超时截断时，可以使用保存的最终观测进行价值自举。
- 03 在重置边界切断优势递推。不得使用下一回合的初始观测，对上一回合的超时状态进行价值自举。
- 04 重复使用同一批数据进行 PPO 小批次更新，再采集新的同策略数据。评估时导出确定性策略网络及其观测变换。

纸笔练习：计算样本数与裁剪目标

- 01 教学算例，并非本次实验：16 个环境 $\times$ 128 步 = 每次采样得到 2,048 条新转移。四轮优化重复使用这些转移，并不会产生 8,192 条新样本。
- 02 当 $\epsilon = 0.2$ 、 $\text{ratio} = 1.4$ 、 $A = +2$ 时： $\min(2.8, 2.4) = 2.4$ 。在求平均和加入其他损失项之前，被最小化的策略项为 -2.4 。
- 03 保持相同的 ratio ，令 $A = -2$ ： $\min(-2.8, -2.4) = -2.8$ 。请解释：优势符号改变后，裁剪为何呈现不对称效果？
- 04 在仓库根目录运行：`python3 docs/microduck-training-student-book/learning_lab.py --gae`。这是确定性的算术练习，不会训练新策略。

奖励设计：智能体因何获得奖励？ · 1/2

- 01 $\text{tracking} = 2.0 * \exp(-(\text{tip_target_distance} / 0.006)^2)$: 平滑的局部跟踪奖励。6 mm 的奖励尺度并不是更严格的 1.5 mm 最终评分容差。
- 02 当实际标记存在状态与请求的落笔状态一致时， $\text{contact} = 0.4$ 。正确的抬笔移动也可获得此奖励；持续接触并非目标。
- 03 维持整个物理子步期间的夹持时， $\text{grasp} = 0.3$ ； $\text{upright} = 0.3 * \max(0, \text{trunk_upright})$ 。平衡和夹持保持提供支持，但不能取代图像几何验收。
- 04 $\text{action_rate_penalty} = -0.01 * \sum((\text{action} - \text{previous_action})^2)$ 用于抑制突变的控制动作。

奖励设计：智能体因何获得奖励？ · 2/2

05

$\text{force_penalty} = -0.02 * \max(0, \text{canvas_force} - 0.5)^2$ 。最终验证还会单独要求峰值力低于 0.5 N。

06

当 loaded_color 等于 desired_color 时， $\text{color} = 0.4$ 。它奖励的是已实现的接触状态；这不能证明 actor 学会了颜色计划，因为 actor 忽略新增的颜色尾部观测。

07

环境返回这些逐步奖励之和。日志保留 reward_mean ，而非完整的回合回报序列。更高的奖励或被接受的锚点更新并不自动意味着绘画质量更好。

记录的训练方案 · 1/3

- 01 选定运行：rlx/runs/studio/drawing/brush-color-v2-03。数据种子 11；训练种子 101；数据集 SHA-256 记录在 training.json 中，并在拟合前与教师侧车文件进行验证。
- 02 岭回归 BC：0.01；两轮 DAgger。各次拟合后的归一化增量 MSE：8.067842827585991e-06、1.9331184375914745e-05 和 3.993013524450362e-05。由于数据集发生变化，这些值不适合作为一条单调可比的学习曲线。
- 03 一个环境；n_steps=6144；八次 rollout 产生 49,152 个新的 transitions。batch_size=512 使每个 epoch 包含 12 个 minibatch；n_epochs=2 是复用数据，而不是将仿真器 transitions 翻倍。
- 04 PPO learning_rate=1e-7；gamma=0.995；gae_lambda=0.95；clip_range=0.05；target_kl=0.002；max_grad_norm=0.3。这些数值来自已归档的训练脚本，并非通用 PPO 默认值。

记录的训练方案 · 2/3

- 05 价值系数 $vf_coef=0.05$ ；熵系数 $ent_coef=0$ 。探索标准差：头部 0.0003、身体/腿部 0.0001、下颚 0.0002。日志中的 `entropy_loss` 并不是熵本身。
- 06 使用基于 4,096 的步幅，从 BC/Dagger 数据中对锚点观测进行子采样。每次更新都将确定性动作与保存的 BC/Dagger actor 进行比较；最大允许漂移为 0.00025。
- 07 全部八次 PPO 更新都通过了漂移门槛。记录的最大 `anchor_max_drift` 为 0.00015974044799804688。验收表示动作漂移约束得到满足，并不代表图像质量存在因果增益。
- 08 ONNX 一致性 `max_absolute_error=1.4901161193847656e-08`, `passed=true`。PPO ONNX SHA-256: 6e083a2a1a0e3114016be9ef0d377d9e9245648ca174303c5f8d0340bdf4500e。

记录的训练方案 · 3/3

09

计数练习：47,984 条初始教师记录；105,858 条最终拟合记录；49,152 个 PPO transitions；每个模型有 $40 * 5,998 = 239,920$ 个评估步；展示轨迹中有 3,484 行接触记录。这些属于不同的数据总体。

实操命令：检查、冒烟测试与训练 · 1/3

01

工作目录：.
PYTHONPATH=rlx:microduck_local/src rlx/.venv-microduck/bin/python
rlx/examples/ppo_microduck_brush.py --help
运行实验前，检查画笔 CLI 及其独立的 93/15 接口。

02

工作目录：.
DATA="\$(mktemp -d /tmp/microduck-brush-data.XXXXXX)"; PYTHONPATH=rlx:microduck_local/src
rlx/.venv-microduck/bin/python rlx/examples/ppo_microduck_brush.py data --out "\$DATA" --
seed 11; printf '%s\n' "\$DATA"
在新的临时目录中创建教师数据。保留输出的 DATA 路径供下一条命令使用；绝不覆盖已发布的数据集。

实操命令：检查、冒烟测试与训练 · 2/3

03

工作目录：.

```
RUN="$(mktemp -d /tmp/microduck-brush-run.XXXXXX)"; PYTHONPATH=rlx:microduck_local/src  
rlx/.venv-microduck/bin/python rlx/examples/ppo_microduck_brush.py train --out "$RUN" --  
data "$DATA/teacher.npz" --seed 101 --steps 49152 --dagger 2 --ridge 0.01 --learning-rate  
1e-7 --anchor-limit 0.00025
```

在同一个 shell 中，将岭回归 BC、两轮 DAgger 和锚定 PPO 训练到新的 RUN 中。此次复现是一个新实验，不保证通过。

04

工作目录：.

```
OUT="$(mktemp -d /tmp/microduck-brush-eval.XXXXXX)"; PYTHONPATH=rlx:microduck_local/src  
rlx/.venv-microduck/bin/python rlx/examples/ppo_microduck_brush.py eval --onnx  
rlx/runs/studio/drawing/brush-color-v2-03/policy.onnx --out "$OUT/ppo-eval.json" --seed  
10001 --episodes 4
```

在十种条件、每种四个种子上评估已发布的 PPO ONNX；写入单独的报告，不要覆盖源证据。

实操命令：检查、冒烟测试与训练 · 3/3

05

工作目录：.

```
OUT="$(mktemp -d /tmp/microduck-brush-bc-eval.XXXXXX)"; PYTHONPATH=rlx:microduck_local/src  
rlx/.venv-microduck/bin/python rlx/examples/ppo_microduck_brush.py eval --onnx  
rlx/runs/studio/drawing/brush-color-v2-03/bc.onnx --out "$OUT/bc-eval.json" --seed 10001 --  
episodes 4
```

使用完全相同的门槛评估匹配的 BC；不要将 PPO 与不匹配的教师或不同任务进行比较。

06


工作目录：.

```
OUT="$(mktemp -d /tmp/microduck-brush-render.XXXXXX)"; PYTHONPATH=rlx:microduck_local/src  
rlx/.venv-microduck/bin/python rlx/examples/render_microduck_brush.py --onnx  
rlx/runs/studio/drawing/brush-color-v2-03/policy.onnx --out "$OUT" --seed 501 --seconds 120
```

在运行时没有教师的情况下渲染已发布的学习型 ONNX。120 s 的请求会完成一条 119.96 s 的人工设计轨迹。

奖励：日志信号与真正的任务目标一致吗？


奖励记录：定义不同的信号，不能混为一谈



训练奖励是优化信号，不是验收标准。完整记录字段见 `raw/<case>/`。

损失：观察策略、价值估计与策略漂移




PPO 优化记录：原始数值，未经平滑



损失更低，不等于机器人技能更好。损失的符号和数值尺度取决于具体实现。

诊断：优化器的行为正常吗？

更新诊断：明确标注未记录的字段



熵、裁剪比例、解释方差和耗时都是诊断指标，不能单独构成通过或失败的证明。

指标矩阵：本次日志的数值审计 · 1/2

- 01 anchor_max_drift: 初始 0.00008613 → 最终 0.0001460; 最小 0.00008613, 最大 0.0001597; 8 个记录样本。
- 02 approx_kl: 首值 0.0002954 → 末值 0.0001603; 最小值 0.00009847, 最大值 0.0002954; 记录了 8 个样本。
- 03 clip_fraction: 首值 0.02808 → 末值 0.01131; 最小值 0.004313, 最大值 0.02808; 记录了 8 个样本。
- 04 entropy_loss: 首值 111.8 → 末值 111.8; 最小值 111.8, 最大值 111.8; 记录了 8 个样本。

指标矩阵：本次日志的数值审计 · 2/2

05 policy_gradient_loss: 首值 -0.0005970 → 末值 -0.0004170 ; 最小值 -0.001051 , 最大值 -0.0002070 ; 记录了 8 个样本。

06 reward_mean: 首值 3.293 → 末值 3.302 ; 最小值 3.293 , 最大值 3.303 ; 记录了 8 个样本。

07 value_loss: 首值 3603 → 末值 3616 ; 最小值 3603 , 最大值 3618 ; 记录了 8 个样本。

验证：查看结果前先定义成功标准 · 1/3

- 01 评估前冻结模型字节。检查 ONNX、检查点、侧车文件、嵌入的训练元数据和已归档训练源代码的哈希；应检查 `provenance_errors`，而不能把文件名当作来源证明。
- 02 十种必测配置：`nominal`；`offset (0.002,0.002) m`；`scale 0.95`；`grip friction 0.9`；`brush stiffness 30 N/m`；`combined_left`；`combined_small`；`combined_right`；`boundary_large`；`boundary_soft`。每种配置的全部四个种子都必须通过。
- 03 组合门槛同时改变 `offset`、`scale`、`friction` 和 `stiffness`。边界覆盖 `scale 0.88` 至 `1.12`、`grip friction 0.8`，以及 `stiffness 18` 至 `40 N/m`；精确配置保留在 `raw/drawing/eval.json` 和源工作流中。
- 04 对于金色、橙色、炭黑色和蓝色中的每一种颜色：在几何容差 `0.0015 m` 下，`coverage >=0.95` 且 `precision >=0.95`。要求完整的 5,998 步轨迹、无跌倒/掉落且 `assistance=0`。

验证：查看结果前先定义成功标准 · 2/3

- 05 安全风格的仿真门槛：grasp_fraction ≥ 0.90 、max_normal_force_n < 0.5 、max_compression_m < 0.0035 、pen_up_leak_fraction < 0.05 。这些是仿真验收检查，不是实体机器人的安全认证。
- 06 要求按 gold $\rightarrow$ orange $\rightarrow$ charcoal $\rightarrow$ blue 顺序从实体调色盘实际加载颜料。null 和 open_jaw 两个负对照都必须失败。用参考目标替换结果或仅展示彩色纹理都不是有效证据。
- 07 使用相同的条件和种子套件评估匹配的 BC。PPO 40/40 和 BC 40/40 支持的是行为保留；无论相同的成功率还是 PPO 略低的精确率，都不能证明 PPO 更优。
- 08 最终 PPO 与匹配 BC 报告均允许只更改评估流水线：training_pipeline_source_match=false、environment_source_match=true、provenance_errors=[]。归档训练脚本仍与各模型匹配。匹配 BC 的强化溯源重评估已于 2026 年 9 月 11 日 21:41:35 UTC 完成。

验证：查看结果前先定义成功标准 · 3/3

09

将渲染的 `source_sha256` 绑定到已评估的 PPO ONNX。另行检查浏览器回执：
`viewer.json` 对一次有界实时检查报告 `passed=false`。离线 ONNX 套件成功并不意味着每项 UI 验证都通过。

结果：实际测量到了什么？ · 1/3

- 01 已发布的 brush-color-v2-03: passed=true、skill_status=passed, 要求的 PPO 回合 40/40 通过, 包含十种独立配置且每种使用四个种子。每次运行完成 5,998 步 / 119.96 s, 且 assistance=0。
- 02 PPO 汇总 mean_coverage=1.0、mean_precision=0.999531977503557。匹配的 BC 也通过 40/40, mean_coverage=1.0、mean_precision=0.9996346455645799。结论: PPO 保留了成功的 BC/DAGger 行为。
- 03 PPO 最差的单色精确率为 0.9862436754827598, 高于 0.95; 最小 grasp_fraction 为 0.9998332777592531。汇总覆盖率不能掩盖某个单独颜色或种子的失败。
- 04 PPO 峰值力 0.040318330721211285 N、峰值压缩量 0.0015517988613261476 m, 最大抬笔泄漏 0.04143426294820717, 均满足声明的门槛。这些是必测评估套件中的最大值, 而不是单帧数据。

结果：实际测量到了什么？ · 2/3

- 05 记录的全部八次更新均通过锚点门槛。reward_mean 从 3.2931220531463623 变为 3.3020718097686768；这一微小变化不能证明绘画有所改进。
- 06 最终 policy_gradient_loss=-0.0004169998671083401；value_loss=3616.0631205240884；approx_kl=0.0001603432756382972；clip_fraction=0.011311848958333334。尽管技能行为被验收，价值损失仍然很大：优化器诊断与任务成功是不同概念。
- 07 与源绑定的展示结果：controller=onnx、teacher_diagnostic=false、assessment passed=true，记录了 3,484 行接触数据并包含全部四种颜色。实际绘制图像来自接触轨迹，而非人工设计的参考图像。
- 08 历史记录保持完整：两次铅笔 PPO 试验均失败；brush-color-v2-01 是初步的 20/20；brush-color-v2-02 使用数据种子 101 时未通过 BC 验证；最终 brush-color-v2-03 使用数据种子 11 和训练种子 101。

结果：实际测量到了什么？ · 3/3

09


独立边界：最终 PPO 与匹配 BC 均报告 `provenance_errors=[]` 和 `environment_source_match=true`。浏览器/实时检查仍报告 `passed=false`。不要把独立模型验收与浏览器验证混为一谈。

成功的 rollout：实际接触绘画



来自已发布 PPO ONNX 的实际四色画笔接触绘画；不是参考目标。完整的 40 回合套件通过，匹配的 BC 也通过。来源：docs/drawing-case/brush/media/render.json。

观看已保存的真实仿真轨迹



播放前


预测一个成功信号和一个失败信号。

播放后

这个片段能支持哪些结论？哪些问题仍未检验？

已保存 120.0 s MP4 • 在 PowerPoint 幻灯片放映中单击 • 备用：videos/drawing-rollout.mp4

历史铅笔教师：另一个 83/15 实验



播放前

预测一个成功信号和一个失败信号。

播放后

这个片段能支持哪些结论？哪些问题仍未检验？

仅代表历史铅笔可行性。这是解析教师，不是 brush-v2 学习得到的 PPO 策略，不是匹配的 BC 基线，也不能证明旧铅笔 PPO 试验曾经通过。 • 已保存 32.0 s MP4 • 在 PowerPoint 幻灯片放映中单击 • 备用：videos/drawing-teacher.mp4

局限与失败分析 · 1/2

- 01 现在已支持成功的固定模板仿真绘画。较早的铅笔实验并未被追溯改判为成功，新的 93/15 画笔契约也不能替代标准 61/14 部署。
- 02 BC/Dagger 已经以略高的精确率通过了相同的 40/40 基准。没有证据确立 PPO 带来改进、从零开始习得该技能或存在单因素因果解释。
- 03 actor 忽略颜色尾部观测 83:93；颜色和蘸取顺序由人工设计。不得将该系统描述为学习得到的颜色规划、视觉、任意绘画或自主漏蘸恢复。
- 04 画笔初始时已在嘴中。拾取、清洗、颜料混合、材料校准、真实伺服器安全和硬件迁移仍未经测试。装饰性刷毛并不是独立仿真的柔性刷毛。

局限与失败分析 · 2/2

05

使用 brush 数据种子 101 的失败尝试表明结果对种子敏感。使用不同种子重复该方案是一次实验，并不保证课堂运行会通过。

06

锚点验收仅限制所选训练观测上的动作漂移。它不是独立的泛化或绘画质量证书；40 回合 ONNX 套件提供了另一份独立证据。

07

本次课堂更新复用已有训练/评估产物及视频，没有重新训练。浏览器验证与未来任何模型重评估都必须独立跟踪。

学生实验：只改一个变量，保留验收标准 · 1/2

01

解释三种契约：标准 61/14、历史铅笔 83/15 和当前画笔 93/15。指出哪个被动柔顺坐标不是额外动作。

02

计算新的 PPO transitions: $1 * 6144 * 8 = 49,152$ 。解释为什么两个优化器 epoch、教师记录和接触行都不是额外的同策略仿真器 transitions。

03

追踪一次 approach → dip → paint 序列。区分人工设计的目标计划、学习得到的电机动作、实体颜料加载和基于接触的评分。

04

从八行 CSV 中读取 reward_mean、policy_gradient_loss、value_loss、approx_kl、clip_fraction、entropy_loss 和 anchor_max_drift。解释为什么 entropy_loss 不是熵，以及为什么 accepted_update 不是成功率曲线。

学生实验：只改一个变量，保留验收标准 · 2/2

05

提出一项受控变更：锚点限制、探索噪声或训练数据种子。保持 BC 基线、源代码哈希、评估条件和验收阈值不变；保留被拒绝的更新和失败运行。

06

比较 40/40 的 BC 和 PPO 表格。写出证据充分支持的最强结论，然后列出声称 PPO 改进了质量、能泛化到未见过的画作或能在实体机器人上工作所缺少证据。

提交一个完整实验，而不只是一段视频

- 01 训练前：写下一个假设、要修改的参数、固定的基线、随机种子列表、验收标准，以及时间与转移数预算。
- 02 训练中：保存准确命令、环境版本、初始化方式、检查点，以及原始奖励、损失和 KL 指标。不得覆盖已有的参考运行。
- 03 训练后：使用相同随机种子评估冻结的导出策略；提交全部失败案例、汇总指标、完整轨迹视频和可追溯来源的结果表。
- 04 评分标准 / 10：可复现性 2；环境与奖励解释 2；PPO 与指标解读 2；如实验验证 2；一个有证据依据的后续实验 2。

来源索引与延伸学习 · 1/2

01

`docs/drawing-case/brush/README.en.md`

02

`docs/drawing-case/brush/RESULTS.md`

03

`docs/drawing-case/brush/DIAGNOSIS.md`

04

`docs/drawing-case/brush/training.json`

来源索引与延伸学习 · 2/2

05

`docs/microduck-training-student-book/chapters/02a-ppo-code-lab.md`

06

`docs/microduck-training-student-book/chapters/02b-gae-workshop.md`

07

`scripts/scenarios/README.md`

08

`README.md`