

实验 02

秋千

秋千：教师辅助习得与 PPO 优化

环境设计 · PPO · 如实验证

构建 → 训练 → 验证 → 讲解



你将构建什么？现有证据说明了什么？

- 01 用例：讲解探索缺口、特权教师标注、仅基于观测的行为克隆、DAgger、严格的物理检查点选择，以及谨慎的 PPO 优化。
- 02 学习目标：描述场景，解释观测到动作的映射和奖励，追踪一次 PPO 更新，运行有限预算实验，并用证据支撑评估结论。
- 03 大幅度行为是通过特权教师标签、BC 和 DAgger 获得的；并非由全新 PPO 发现。
- 04 适用范围：本地 MuJoCo 仿真。请勿将课堂产物直接部署到实体机器人；硬件迁移需要独立且经过验证的流程。

材料与准备条件 · 1/2

- 01 配备已安装的 RLX 环境、MLX、MuJoCo、ONNX、ONNX Runtime、渲染依赖项和 Node 的 Apple Silicon Mac。
- 02 受跟踪的教师定义：docs/remaining-scenarios-e2e/recipes/swing-teacher.json。
- 03 秋千模拟器资产：保留的座椅、绑带、卡扣、缓冲器、框架、锚点、附件和两条柔顺肌腱。
- 04 引导工具：rlx/scripts/bootstrap_swing_e2e.py；PPO/评估/导出工具：rlx/examples/ppo_microduck_studio.py。

材料与准备条件 · 2/2

05

已保存引导来源信息、演示数据、所选初始化器、PPO 检查点、sidecar、ONNX 策略网络（Actor）、审计轨迹和 MP4。

环境与策略接口约定 · 1/2

- 01 50 Hz 下的标称 XML MuJoCo 秋千；通过的评估从角度 0 deg、角速度 0 rad/s 开始，运行 1,200 步或 24 秒。
- 02 观测保持为 float32 batch x 61；部署的策略网络（Actor）输入不会附加特权秋千角度或角速度。
- 03 秋千命令槽为 twist 48:51 = (0, body-y-axis-x, body-y-axis-z)；头部和身体命令块为零。
- 04 策略网络（Actor）输出 14 个值；封装器将其裁剪至 $[-1,1]$ ，投影到矢状面对称空间，并将目标设为 SEATED_POSE + $0.7 \times \text{projected action}$ 。

环境与策略接口约定 · 2/2

05

偏航/横滚动作索引 0,1,7,8,9,10 被置零；腿部俯仰/膝/踝关节对大小相等、方向相反；颈部和头部俯仰保持独立。

06

所选运行禁用了域随机化、观测噪声、动作延迟、随机偏航和辅助评估起始状态。

案例构建流程：以证据形成验证闭环



失败也是数据：每次只改变一个因素，重新训练，并使用相同的验收标准。

逐步构建本案例 · 1/2

- 01 使用有界特权教师，在四组角度/角速度重置边界下收集八个 1,200 步回合，得到 9,600 行带标签数据。
- 02 使用传感器块方差下限，根据最初的 9,600 个观测冻结观测归一化。
- 03 通过行为克隆训练策略网络（Actor）均值，然后在学习器访问的状态上，使用学生动作和教师标签运行 DAgger。
- 04 对每个 BC/DAgger 阶段进行物理评估；选择阶段 3 是因为它通过了评估，而不是因为其监督损失最低。

逐步构建本案例 · 2/2

05 将所选检查点和 sidecar 复制到全新的 Studio 运行中；保留随机价值网络（Critic），并声明教师辅助和 ppo_steps 0。

06 使用 524,288 次 PPO 转移、冻结的观测归一化、全新的 Adam 状态和奖励归一化来优化策略网络（Actor）和价值网络（Critic）。

07 导出确定性 ONNX，运行严格的静止起始评估，审计已训练/初始/零动作/随机动作对照，并验证完整视频。

PPO：改进策略，同时避免盲目迈出过大一步

$$\text{似然比 ratio} = \pi_{\text{new}}(a \mid o) / \pi_{\text{old}}(a \mid o)$$

最大化 $\text{mean}[\min(\text{ratio} \times A, \text{clip}(\text{ratio}, 1 - \epsilon, 1 + \epsilon) \times A)]$

策略网络（Actor）：选择关节动作。价值网络（Critic）：估计未来折扣奖励。

A 表示优势； ϵ 表示裁剪范围。每个采样批次的旧策略对数概率在更新时保持不变。

沿着一次轨迹采样，理解学习器的处理过程

- 01 使用当前随机策略采集观测、采样动作、旧策略对数概率、价值估计、奖励以及回合边界标记。
- 02 计算时序差分残差和广义优势估计（GAE）。真正终止时，后续价值为零；超时截断时，可以使用保存的最终观测进行价值自举。
- 03 在重置边界切断优势递推。不得使用下一回合的初始观测，对上一回合的超时状态进行价值自举。
- 04 重复使用同一批数据进行 PPO 小批次更新，再采集新的同策略数据。评估时导出确定性策略网络及其观测变换。

纸笔练习：计算样本数与裁剪目标

- 01 教学算例，并非本次实验：16 个环境 $\times$ 128 步 = 每次采样得到 2,048 条新转移。四轮优化重复使用这些转移，并不会产生 8,192 条新样本。
- 02 当 $\epsilon = 0.2$ 、 $\text{ratio} = 1.4$ 、 $A = +2$ 时： $\min(2.8, 2.4) = 2.4$ 。在求平均和加入其他损失项之前，被最小化的策略项为 -2.4 。
- 03 保持相同的 ratio ，令 $A = -2$ ： $\min(-2.8, -2.4) = -2.8$ 。请解释：优势符号改变后，裁剪为何呈现不对称效果？
- 04 在仓库根目录运行：`python3 docs/microduck-training-student-book/learning_lab.py --gae`。这是确定性的算术练习，不会训练新策略。

奖励设计：智能体因何获得奖励？ · 1/2

- 01 swing_peak_progress 224: 仅当达到新的正向或负向角度前沿时，才给予有界增量奖励。
- 02 swing_height 8、swing_late_height 24 和 swing_energy 0.5 奖励相对于重置基线的有效高度和机械能增益。
- 03 swing_lateral_penalty 3、lateral_barrier 8、lateral_velocity 3 和 out_of_plane 1 惩罚非矢状面运动。
- 04 swing_alignment_penalty 18 和 alignment_barrier 4 惩罚座椅/绳索几何结构未对齐。

奖励设计：智能体因何获得奖励？ · 2/2

05

`string_slack_penalty` 8 和 `string_extension_penalty` 12 保护声明的肌腱长度区间。

06

`invalid_episode_penalty` 10、`action_rate_penalty` 0.03、`joint_torque_penalty` 0.001 和 `joint_limit_penalty` 1 均已启用。

已记录的训练配置 · 1/2

- 01 所选初始化器：BC 加同策略 DAgger，阶段 3，38,400 行教师标注数据，严格通过，teacher_samples 38,400，ppo_steps 0。
- 02 最终演示数据归档有 57,600 行，因为阶段 3 之后仍继续收集；它并非所选检查点的训练集。
- 03 PPO：seed 7，524,288 次转移，16 个 fork 环境，每个环境 256 步，每次 rollout 4,096 次转移，共 128 个 rollout/更新周期。
- 04 四个小批次 x 两个 epoch 得到每个小批次 1,024 行，每次 rollout 8 个优化器步骤，总计 1,024 个优化器步骤。

已记录的训练配置 · 2/2

05 学习率 0.000003；gamma 0.995；广义优势估计（GAE）lambda 0.98；clip 0.05；价值系数 1；熵系数 0；最大梯度范数 0.5。

06 初始标准差 0.1 通过模仿过程序列化；PPO 使用全新的 Adam 优化器，并冻结观测统计数据更新。

07 更新日志字段：phase、steps、seconds、optimizer_steps、mean_loss、policy_loss、value_loss、entropy、approximate_kl、clip_fraction、explained_variance、env_steps。

实操命令：检查、冒烟测试与训练 · 1/3

01

工作目录：.
`./scripts/train-swing.sh --dry-run`
在不训练的情况下检查完整的教师初始化和 PPO 流水线。

02

工作目录：.
`./scripts/train-swing.sh`
运行独立的 Full Swing 引导、PPO、导出、评估和渲染流水线。

实操命令：检查、冒烟测试与训练 · 2/3

03

工作目录：.
`rlx/.venv-microduck/bin/python rlx/scripts/bootstrap_swing_e2e.py --source docs/remaining-scenarios-e2e/recipes/swing-teacher.json --output /tmp/swing-bootstrap-reproduction-YYYYMMDD-HHMMSS`
创建教师辅助初始化器；一致地替换时间戳标记。

04

工作目录：.
`rlx/.venv-microduck/bin/python rlx/scripts/audit_scenarios.py --recipe-json docs/remaining-scenarios-e2e/recipes/swing.json --run rlx/runs/studio/swing/swing-reproduction-YYYYMMDD-HHMMSS --output rlx/artifacts/scenarios-e2e-20260907/swing-reproduction-YYYYMMDD-HHMMSS-audit --seeds 501 502 503 504 505 --render`
使用五个确定性 seed 审计已完成的 Swing 复现。

实操命令：检查、冒烟测试与训练 · 3/3

05


工作目录：.

```
jq '{selected_stage, samples, normalizer_frozen_sample_count, limitations}' /tmp/swing-bootstrap-reproduction-YYYYMMDD-HHMMSS/provenance.json
```

检查所选引导阶段、样本数、冻结的归一化器和声明的限制。

奖励：日志信号与真正的任务目标一致吗？




奖励记录：定义不同的信号，不能混为一谈



训练奖励是优化信号，不是验收标准。完整记录字段见 `raw/<case>/`。

损失：观察策略、价值估计与策略漂移





PPO 优化记录：原始数值，未经平滑



损失更低，不等于机器人技能更好。损失的符号和数值尺度取决于具体实现。

诊断：优化器的行为正常吗？

更新诊断：明确标注未记录的字段



熵、裁剪比例、解释方差和耗时都是诊断指标，不能单独构成通过或失败的证明。

指标矩阵：本次日志的数值审计 · 1/3

- 01 approximate_kl: 首次 0.007981 → 最终 0.0004294; 最小值 0.0001979, 最大值 0.007981; 记录了 128 个样本。
- 02 clip_fraction: 首次 0.5221 → 最终 0.09058; 最小值 0.03223, 最大值 0.5221; 记录了 128 个样本。
- 03 entropy: 首次 -12.37 → 最终 -12.37; 最小值 -12.37, 最大值 -12.37; 记录了 128 个样本。
- 04 explained_variance: 首次 -0.002574 → 最终 -3.963; 最小值 -4.591, 最大值 0.4628; 记录了 128 个样本。

指标矩阵：本次日志的数值审计 · 2/3

- 05 mean_loss: 首次 1.889 → 最终 0.0001821; 最小值 -0.0003026, 最大值 8.735; 记录了 128 个样本。
- 06 mean_raw_return: 首次 2670 → 最终 -4533; 最小值 -3.695e+4, 最大值 5725; 记录了 27 个样本。
- 07 mean_reward: 首次 -0.001981 → 最终 0.0001209; 最小值 -0.07257, 最大值 0.03519; 记录了 128 个样本。
- 08 policy_loss: 首次 0.01469 → 最终 -0.0007164; 最小值 -0.001231, 最大值 0.01469; 记录了 128 个样本。

指标矩阵：本次日志的数值审计 · 3/3

09

value_loss: 首次 1.874 → 最终 0.0008984; 最小值 0.0003912, 最大值 8.733;
记录了 128 个样本。

验证：查看结果前先定义成功标准 · 1/2

- 01 要求每个通道有一个完整的 1,200 步静止起始回合，并且每个回合内对称双向跨度 ≥ 150 deg。
- 02 要求每个样本的横向偏移 ≤ 0.020 m、对齐误差 ≤ 0.050 、绳索长度为 0.370–0.394 m、几何结构有效且张力为正。
- 03 不接受将一个回合的正峰值与另一个回合的负峰值合并；所有回合都必须独立通过。
- 04 确认导出的策略网络（Actor）仅接受 61 个观测并输出 14 个动作；特权角度/角速度访问仅限于教师标注。

验证：查看结果前先定义成功标准 · 2/2

05

将最终 PPO 策略与所选初始化器、零动作和随机动作进行比较；要求负面对照无法通过技能门槛。

06

验证检查点和 sidecar 哈希、JSONL 有限值、动态 batch x 61 到 x 14 ONNX、一致性 $\leq 1e-4$ 、已解码 MP4 和浏览器播放。

结果：实际测量到了什么？ · 1/3

- 01 实际最终证据：swing-e2e-20260907-v3 为 PASS；Studio 评估通过了 16/16 个完整的 24 秒回合。
- 02 独立 seed 501-505 通过 5/5；标称确定性重置产生了相同的 162.3215866231874 deg 双向跨度。
- 03 最终峰值为 +82.94345706612039 和 -81.1607933115937 deg；最大横向偏移 0.00901905817024827 m；最大对齐误差 0.04606865972943153。
- 04 有效几何结构比例和双绳有张力比例均为 1.0；绳索长度保持在 0.38010451970068404-0.38667901638228347 m。

结果：实际测量到了什么？ · 2/3

- 05 采样到的最小弹簧张力为 0.20903940136807186 N；确定性原始回报为 7016.894722654329。
- 06 所选模仿初始化器已经以约 154.62 deg 跨度和原始回报 6126.39 通过；PPO 将回报提高了 890.5029066062816。
- 07 PPO 使学习张量产生了 L2 0.4897554898284089 的变化；ONNX/原生最大动作误差为 $1.1324882507324219e-6$ 。
- 08 Final-100 均值：policy_loss -0.00032241872322629205, value_loss 0.37311747095896863, mean_loss 0.37279505291702664。

结果：实际测量到了什么？ · 3/3


09

Final-100 approximate_kl 0.00047223041314282455, clip_fraction 0.0969189453125, explained_variance -0.8998712115795674。

10

从零开始的 PPO 运行仅达到约 2.23 deg 跨度；继续进行 1,048,576 次转移虽然保持了较大跨度，但未通过几何结构和张力要求。

观看已保存的真实仿真轨迹



已保存的 24.0 s MP4 • 在 PowerPoint 幻灯片放映中单击 • 备用: [videos/swing-rollout.mp4](#)

播放前

预测一个成功信号和一个失败信号。

播放后

这个片段能支持哪些结论？哪些问题仍未检验？

局限与失败分析 · 1/2

- 01 大幅度行为是通过特权教师标签、BC 和 DAgger 获得的；并非由全新 PPO 发现。
- 02 所选标称 seed 几乎完全相同，因为随机化、噪声、延迟、偏航和非零起始边界均已禁用。
- 03 采样到的正弹簧张力不包括安全限位约束力，也不能证明连续时间或硬件负载安全性。
- 04 尽管确定性策略网络（Actor）通过了单独的物理门槛，但从 explained_variance 看，价值网络（Critic）的拟合仍然较差。

局限与失败分析 · 2/2

05

通过的结果使用标称 XML 模拟、一个教师族、一个 PPO seed、平面动作，并且没有扰动或 BAM 评估。

06

进一步的 PPO 可能损害已经胜任的策略；被拒绝的百万次转移检查点不是可接受的替代方案。

学生实验：只改一个变量，保留验收标准 · 1/2

- 01 建议练习，并非已保存证据：推导 13 参数教师方程，并将其五个矢状面输出映射为 14 个动作。
- 02 建议练习，并非已保存证据：验证阶段 0 至 5 的累计 DAgger 行数和优化器更新次数。
- 03 建议练习，并非已保存证据：列出交接时的策略网络（Actor）、价值网络（Critic）、log std、观测归一化器、回报归一化器和优化器。
- 04 建议练习，并非已保存证据：推导每次 rollout 4,096 次转移、128 次 rollout 和 1,024 个 PPO 优化器小批次。

学生实验：只改一个变量，保留验收标准 · 2/2

05

建议练习，并非已保存证据：解释为什么阶段 4 或 5 更低的 BC 损失不能推翻物理门槛未通过的结果。

提交一个完整实验，而不只是一段视频

- 01 训练前：写下一个假设、要修改的参数、固定的基线、随机种子列表、验收标准，以及时间与转移数预算。
- 02 训练中：保存准确命令、环境版本、初始化方式、检查点，以及原始奖励、损失和 KL 指标。不得覆盖已有的参考运行。
- 03 训练后：使用相同随机种子评估冻结的导出策略；提交全部失败案例、汇总指标、完整轨迹视频和可追溯来源的结果表。
- 04 评分标准 / 10：可复现性 2；环境与奖励解释 2；PPO 与指标解读 2；如实验验证 2；一个有证据依据的后续实验 2。

来源索引与延伸学习 · 1/2

01

AGENTS.md

02

microduck_local/AGENTS.md

03

README.md

04

rlx/README.md

来源索引与延伸学习 · 2/2

05

`docs/microduck-training-student-book/chapters/02a-ppo-code-lab.md`

06

`docs/microduck-training-student-book/chapters/02b-gae-workshop.md`

07

`scripts/scenarios/README.md`

08

`README.md`